



Detección de Anomalías Sísmicas con Inteligencia Artificial

1. Resumen Ejecutivo

La sismología moderna enfrenta un desafío crítico: la limitada capacidad de monitoreo y alerta temprana en vastas zonas rurales, dejando a estas comunidades vulnerables a eventos sísmicos devastadores. Los métodos tradicionales son insuficientes para manejar grandes volúmenes de datos y detectar eventos sutiles, mientras que la Inteligencia Artificial (IA) presenta brechas significativas en la gestión de datos escasos y heterogéneos y en la generalización de modelos. Este proyecto, "Detección de Anomalías Sísmicas con Inteligencia Artificial", propone una solución innovadora para desarrollar y validar un sistema basado en IA que mejore el monitoreo y la capacidad de alerta temprana en estas regiones desatendidas, protegiendo a las poblaciones y reduciendo riesgos.

Para lograr esta visión, el proyecto se centrará en el desarrollo de algoritmos de IA robustos, específicamente diseñados para operar con datos sísmicos limitados y heterogéneos. Simultáneamente, optimizaremos estos modelos para asegurar una alta capacidad de generalización a través de diversas configuraciones geológicas. La eficacia del sistema será validada rigurosamente mediante su implementación y prueba en un entorno piloto rural. Todo esto se llevará a cabo bajo el marco estructurado de la metodología CRISP-DM, asegurando un proceso iterativo y orientado a los datos para el desarrollo y la optimización continua.

Los resultados clave incluyen un paquete de algoritmos y modelos de IA robustos y optimizados, junto con un sistema prototipo validado en un entorno real, demostrando una reducción del tiempo de detección del 30% y una tasa de falsas alarmas inferior al 10%. Esto generará un impacto técnico significativo al avanzar el estado del arte en sismología con IA, un impacto económico al reducir pérdidas y crear nuevas oportunidades, y un

impacto social crucial al mejorar la seguridad y resiliencia de las comunidades rurales vulnerables.

Este proyecto representa un esfuerzo fundamental e innovador para transformar el monitoreo sísmico, sentando las bases para una mayor resiliencia ante los fenómenos naturales y una protección más inclusiva para todas las comunidades.

2. Generalidades del Proyecto

- **Descripción:** El proyecto tiene como objetivo principal la detección de anomalías sísmicas en zonas rurales. Para ello, se empleará inteligencia artificial con el fin de identificar patrones inusuales. La finalidad es mejorar la capacidad de monitoreo y alerta temprana de eventos sísmicos en estas áreas.
- **Palabras Clave:** Detección de Anomalías, Sismología, Inteligencia Artificial, Zonas Rurales

3. Planteamiento del Problema y Justificación

La sismología, ciencia fundamental para comprender la dinámica terrestre y mitigar los riesgos asociados a los eventos sísmicos, enfrenta desafíos considerables en la actualidad. A nivel global, la necesidad de proteger a las comunidades y la infraestructura de los impactos devastadores de los terremotos es una prioridad. Sin embargo, en las vastas y a menudo poco instrumentadas zonas rurales, la capacidad de monitoreo y, consecuentemente, la emisión de alertas tempranas precisas y oportunas, sigue siendo una limitación significativa, dejando a estas poblaciones en una situación de mayor vulnerabilidad.

Como la literatura especializada indica (Aminzadeh, 2003), la detección tradicional de anomalías sísmicas ha dependido en gran medida de la interpretación experta y de métodos estadísticos, lo que ha demostrado ser insuficiente para manejar grandes volúmenes de datos y para identificar eventos sutiles. La irrupción de la Inteligencia Artificial (IA) ha demostrado un potencial transformador en la sismología (Kubo, Naoi & Kano, 2024; Giunchi & Sadeghian, 2019; Sriram, Rahnamayan & Bourennani, 2014; Yousefpour y Mojtahedi, 2023), pero el estado del arte presenta brechas críticas, especialmente en el contexto de las zonas rurales. La "Revisión de la Literatura" y "Brechas de Conocimiento y Oportunidades" resaltan una escasez y heterogeneidad fundamental de datos sísmicos en estas regiones, lo que dificulta el entrenamiento de modelos robustos de IA. Adicionalmente, la generalización de modelos entrenados en una región a otra es un desafío significativo debido a las variaciones geológicas, creando una "brecha tecnológica" en la aplicación efectiva y escalable de la IA para el monitoreo sísmico rural.

Este proyecto, titulado "Detección de Anomalías Sísmicas con Inteligencia Artificial", se erige como la respuesta directa y necesaria para subsanar estas deficiencias. Al centrarse explícitamente en el desarrollo de modelos de inteligencia artificial diseñados para operar de manera eficiente con datos limitados y heterogéneos, el proyecto abordará las limitaciones de la escasez de instrumentación en áreas rurales. La estrategia propuesta, que incluye la exploración de técnicas como el aprendizaje por transferencia o la integración de diversas fuentes de datos (sísmicos, geodésicos, hidrológicos), permitirá crear un sistema de monitoreo más resiliente y adaptable, superando las barreras actuales de la generalización y la calidad de los datos.

La relevancia estratégica de este proyecto es innegable. Su enfoque en la detección de anomalías sísmicas en zonas rurales no solo es oportuno, sino crítico, dado que estas áreas a menudo carecen de la infraestructura de monitoreo adecuada y son más vulnerables a los impactos de los eventos sísmicos. Al mejorar la capacidad de monitoreo y alerta temprana, el proyecto generará un impacto significativo en la seguridad de las comunidades, la planificación de la respuesta a emergencias y la reducción de riesgos a nivel regional. Este esfuerzo innovador representa un paso fundamental hacia un monitoreo sísmico más inclusivo, adaptable y eficaz, sentando las bases para una mayor resiliencia frente a los fenómenos naturales.

4. Marco Teórico y Estado del Arte

4.1. Introducción al Dominio

La sismología, el estudio de los terremotos y la propagación de ondas elásticas a través de la Tierra, es fundamental para comprender la dinámica terrestre y mitigar los riesgos asociados a eventos sísmicos. La detección de anomalías sísmicas se refiere a la identificación de patrones inusuales en los datos sísmicos que pueden preceder o indicar la, es fundamental para comprender la dinámica terrestre y mitigar los riesgos asociados a eventos sísmicos. La detección de anomalías sísmicas se refiere a la identificación de patrones inusuales en los datos sísmicos que pueden preceder o indicar la ocurrencia de un evento sísmico significativo, o bien, revelar fenómenos geofísicos subyacentes como la actividad volcánica o la migración de fluidos (Aminzadeh, 2003). Tradicionalmente, este proceso ha dependido en gran medida de la interpretación experta y de métodos estadísticos, lo que a menudo resulta en limitaciones en la detección de eventos sutiles o en la gestión de grandes volúmenes de datos.

La irrupción de la Inteligencia Artificial (IA), y en particular el aprendizaje automático (Machine Learning, ML) y el aprendizaje profundo (Deep Learning, DL), ha transformado la capacidad de análisis en diversas disciplinas científicas, incluyendo la sismología. Estas tecnologías permiten identificar patrones complejos y no lineales en grandes conjuntos de datos, superando las limitaciones de los enfoques manuales o puramente estadísticos (Kubo, Naoi & Kano, 2024). La aplicación de la IA en la detección de anomalías sísmicas ofrece una oportunidad sin precedentes para mejorar la precisión, la eficiencia y la capacidad de alerta temprana, especialmente en contextos donde el monitoreo tradicional es desafiante, como las zonas rurales.

4.2. Revisión de la Literatura

La literatura reciente demuestra un creciente interés en la aplicación de la IA para la detección de anomalías sísmicas y la comprensión de los fenómenos terrestres. Un trabajo relevante es el de **Giunchi y Sadeghian (2019)**, quienes exploraron el reconocimiento de fases sísmicas basado en redes neuronales de memoria a largo corto plazo (LSTM) y la detección de anomalías. Este enfoque subraya el potencial de las arquitecturas de redes recurrentes para procesar secuencias de datos sísmicos y aprender representaciones temporales que son cruciales para identificar desviaciones del comportamiento normal.

En una línea similar, **Sriram, Rahnamayan y Bourennani (2014)** revisaron el uso de Redes Neuronales Artificiales (ANNs) para la detección de anomalías sísmicas. Su trabajo destacó cómo las ANNs pueden evaluar una combinación de precursores sísmicos, aumentando la posibilidad de detectar eventos

inminentes. Aunque más antiguo, este estudio sentó las bases para el uso de modelos de IA en la sismología, enfatizando la capacidad de las redes neuronales para aprender relaciones complejas en los datos.

Más recientemente, **Yousefpour y Mojtahedi (2023)** propusieron un método innovador para la detección temprana de erosión interna en presas de tierra, combinando el monitoreo sísmico con AutoEncoders convolucionales. Este estudio es particularmente relevante por su aplicación de una técnica de aprendizaje profundo no supervisado para la detección de anomalías en datos sísmicos de series temporales. Los AutoEncoders convolucionales demostraron la capacidad de identificar patrones temporales asociados con la iniciación de la erosión interna, lo que podría traducirse en la detección de otras anomalías en el contexto de la sismología general.

Otros estudios, como el de **Lyu, Wang, Yong y Huang (2019)**, han propuesto métodos específicos para la detección de anomalías en datos de geo-sonido sísmico utilizando operadores de Baer, lo que demuestra la diversidad de enfoques basados en IA para diferentes tipos de datos precursoros. Estos trabajos colectivamente establecen un marco donde la IA, a través de diversas arquitecturas y algoritmos, es una herramienta poderosa para extraer información crítica de los datos sísmicos que de otro modo sería difícil de discernir.

4.3. Tecnologías y Enfoques Actuales

El estado del arte en la detección de anomalías sísmicas con inteligencia artificial se caracteriza por la adopción de algoritmos avanzados de aprendizaje automático y aprendizaje profundo. Las técnicas más prominentes incluyen:

- **Redes Neuronales Convolucionales (CNNs):** Ampliamente utilizadas para el procesamiento de imágenes y series temporales, las CNNs son efectivas para extraer características espaciales y temporales de los sismogramas. Se emplean en la clasificación de eventos sísmicos, la detección de fases y la identificación de patrones anómalos.
- **Redes Neuronales Recurrentes (RNNs) y LSTMs:** Ideales para datos de series temporales, las RNNs y sus variantes como las LSTMs (Giunchi & Sadeghian, 2019) son capaces de capturar dependencias a largo plazo en los datos sísmicos, lo que es crucial para predecir anomalías o identificar precursoros.
- **AutoEncoders (AEs) y Variantes (VAEs, CAE):** Estos modelos de aprendizaje no supervisado son particularmente aptos para la detección de anomalías. Un AutoEncoder aprende a reconstruir sus datos de entrada; las desviaciones significativas entre la entrada y su reconstrucción indican una anomalía. Los AutoEncoders convolucionales (CAE), como los utilizados por Yousefpour y Mojtahedi (2023), combinan la capacidad de extracción de características de las CNNs con la detección de anomalías de los AEs.
- **Machine Learning Científico (SciML):** Una tendencia emergente que integra el aprendizaje automático con la teoría física. Okazaki (2024) describe cómo SciML, a través de redes neuronales informadas por la física (PINNs) y operadores neuronales (NOs), reduce la dependencia de datos extensos e incorpora leyes físicas en los modelos, mejorando la comprensión y predicción de fenómenos complejos.

- **Aprendizaje por Refuerzo:** Aunque menos común, el aprendizaje por refuerzo se explora para optimizar las redes de sensores sísmicos o para guiar la exploración de patrones anómalos en tiempo real.

El monitoreo sísmico moderno, especialmente en zonas con instrumentación limitada como las áreas rurales, se beneficia enormemente de estos enfoques. La IA permite el procesamiento eficiente de grandes volúmenes de datos sísmicos, la identificación de eventos sísmicos menores que antes pasaban desapercibidos y la mejora de la capacidad de alerta temprana (Infobae, 2025; Yahoo Noticias, 2019). Las plataformas actuales buscan integrar la teledetección (satélites, drones) con redes instrumentales (estaciones sísmicas) para generar bases de datos robustas, sobre las cuales los modelos de IA pueden operar eficazmente (WMO, 2023).

4.4. Brechas de Conocimiento y Oportunidades

A pesar de los avances significativos, existen varias brechas de conocimiento y oportunidades en la detección de anomalías sísmicas con IA, especialmente en el contexto de zonas rurales. Una limitación fundamental es la **escasez y heterogeneidad de los datos sísmicos** en estas regiones. Las zonas rurales a menudo carecen de la densidad de estaciones sísmicas que se encuentran en áreas urbanas o de alto riesgo geológico, lo que dificulta el entrenamiento de modelos de IA robustos que requieren grandes volúmenes de datos etiquetados. Además, la calidad de los datos puede variar, presentando desafíos en términos de ruido y consistencia.

Otra brecha radica en la **generalización de modelos de IA** entrenados en una región a otra. Los patrones sísmicos y las características geológicas varían significativamente, lo que significa que un modelo efectivo en una zona puede no serlo en otra sin una adaptación o reentrenamiento considerable. Esto es particularmente relevante para las zonas rurales, que pueden tener características geológicas únicas y menos estudiadas.

El proyecto propuesto aborda estas brechas al centrarse explícitamente en la detección de anomalías sísmicas en zonas rurales, donde la capacidad de monitoreo y alerta temprana es más crítica y menos desarrollada. La oportunidad reside en desarrollar modelos de IA que sean eficientes con datos limitados, posiblemente empleando técnicas como el aprendizaje por transferencia, el aprendizaje federado o arquitecturas de modelos ligeras. Además, la investigación puede explorar cómo la IA puede integrar diversas fuentes de datos (sísmicos, geodésicos, hidrológicos) para compensar la escasez de una sola fuente, creando un sistema de monitoreo más resiliente y adaptable a las condiciones específicas de las zonas rurales.

5. Objetivos

Objetivo General

Desarrollar y validar un sistema innovador de detección de anomalías sísmicas basado en Inteligencia Artificial para mejorar el monitoreo y la capacidad de alerta temprana en zonas rurales con datos sísmicos limitados y heterogéneos, contribuyendo a la reducción de riesgos y la protección de comunidades vulnerables.

Objetivos Específicos

1. **Objetivo:** Desarrollar algoritmos de Inteligencia Artificial robustos para datos sísmicos limitados y heterogéneos.

- **Específico (S):** Investigar, diseñar e implementar algoritmos de IA (ej., aprendizaje por transferencia, redes neuronales) capaces de procesar y aprender eficazmente de conjuntos de datos sísmicos limitados y heterogéneos característicos de zonas rurales.
- **Medible (M):** Lograr una precisión de clasificación de anomalías sísmicas superior al 85% en conjuntos de datos sintéticos y reales limitados, y demostrar una mejora del 15% en el rendimiento del modelo en comparación con métodos tradicionales en condiciones de escasez de datos, medido mediante métricas como F1-score y AUC.
- **Alcanzable (A):** Es realista dado el estado actual de la investigación en IA y las técnicas de aprendizaje por transferencia, que permiten el entrenamiento con menos datos o la adaptación de modelos pre-entrenados.
- **Relevante (R):** Este objetivo es fundamental para superar la barrera principal de la escasez y heterogeneidad de datos en zonas rurales, lo cual es crucial para el éxito del proyecto y la viabilidad del monitoreo sísmico con IA en estas áreas.
- **Plazo (T):** Completar la investigación, desarrollo y validación de los algoritmos robustos en los primeros 12 meses del proyecto.

2. **Objetivo:** Optimizar modelos de IA para una alta capacidad de generalización en diversas configuraciones geológicas.

- **Específico (S):** Desarrollar y optimizar modelos de IA que demuestren una alta capacidad de generalización para detectar anomalías sísmicas en diversas configuraciones geológicas y regiones rurales no utilizadas en el entrenamiento inicial.
- **Medible (M):** Validar la generalización de los modelos obteniendo una reducción del error de predicción de anomalías en un 20% en al menos tres regiones geológicamente distintas, utilizando conjuntos de datos de prueba independientes, y mantener una precisión de detección superior al 80% en estas nuevas regiones.
- **Alcanzable (A):** Las técnicas avanzadas de IA como el aprendizaje federado o el meta-aprendizaje, junto con la integración de diversas fuentes de datos, ofrecen caminos prometedores para lograr una mejor generalización.
- **Relevante (R):** Aborda directamente la "brecha tecnológica" de la falta de generalización, permitiendo que la solución sea escalable y aplicable en un amplio rango de zonas rurales, lo cual es clave para el impacto estratégico del proyecto.
- **Plazo (T):** Alcanzar los criterios de generalización y validación en las regiones de prueba antes del mes 18 del proyecto.

3. **Objetivo:** Validar la eficacia del sistema de detección de anomalías sísmicas en un entorno piloto rural.

- **Específico (S):** Validar la eficacia del sistema de detección de anomalías sísmicas basado en IA mediante su implementación y prueba en un entorno simulado o piloto en una zona rural específica, evaluando su rendimiento en tiempo real para la emisión de alertas.
- **Medible (M):** Demostrar una reducción del tiempo de detección de anomalías sísmicas en un 30% en comparación con los métodos actuales y lograr una tasa de falsas alarmas inferior al 10% durante un período de prueba de 6 meses en el entorno piloto.
- **Alcanzable (A):** La validación en un entorno piloto es una fase estándar en proyectos de I+D y es factible una vez que los modelos de IA han sido desarrollados y optimizados.
- **Relevante (R):** Este objetivo final conecta directamente el desarrollo tecnológico con la aplicación práctica y el impacto real, contribuyendo a la seguridad de las comunidades y la planificación de la respuesta a emergencias, que es el fin último del proyecto.
- **Plazo (T):** Implementar y completar la fase de validación en el entorno piloto y presentar un informe de resultados dentro de los 24 meses del proyecto.

6. Metodología Propuesta

Framework Seleccionado: CRISP-DM (Cross-Industry Standard Process for Data Mining)

La metodología CRISP-DM es seleccionada por ser el estándar de facto para proyectos de ciencia de datos y aprendizaje automático, lo cual se alinea perfectamente con la naturaleza de investigación y desarrollo de algoritmos de Inteligencia Artificial de este proyecto. Su estructura iterativa y orientada a los datos es idónea para abordar los desafíos de datos sísmicos limitados y heterogéneos (Objetivo 1), permitiendo la optimización continua de modelos para una alta capacidad de generalización (Objetivo 2) y culminando en una fase de validación rigurosa en un entorno piloto (Objetivo 3), asegurando que el sistema desarrollado sea robusto y eficaz en su aplicación real.

Fases Principales de la Metodología:

- **Fase 1: Comprensión del Negocio** - Se enfoca en definir detalladamente los objetivos del proyecto desde una perspectiva de negocio, identificar los criterios de éxito y comprender el contexto y los requisitos específicos para la detección de anomalías sísmicas en zonas rurales.
- **Fase 2: Comprensión de los Datos** - Implica la recolección, exploración inicial y análisis de los conjuntos de datos sísmicos disponibles, identificando la calidad de los datos, sus características principales y los desafíos inherentes a la escasez y heterogeneidad de los mismos.
- **Fase 3: Preparación de los Datos** - Consiste en las actividades de limpieza, integración, transformación y selección de datos sísmicos, aplicando técnicas avanzadas para manejar datos limitados y preparar los conjuntos de entrenamiento y prueba para los modelos de IA.
- **Fase 4: Modelado** - Se centra en la selección, diseño e implementación de algoritmos de Inteligencia Artificial (ej. aprendizaje por transferencia, redes neuronales), así como en el entrenamiento y ajuste iterativo de los modelos para lograr la detección robusta de anomalías sísmicas y su optimización para la

generalización.

- **Fase 5: Evaluación** - Comprende la evaluación exhaustiva del rendimiento de los modelos desarrollados utilizando métricas clave (ej. precisión, F1-score, AUC) y conjuntos de datos de validación independientes, verificando la capacidad de generalización en diversas configuraciones geológicas y asegurando el cumplimiento de los objetivos medibles.
- **Fase 6: Despliegue** - Implica la implementación del sistema de detección de anomalías sísmicas basado en IA en un entorno piloto rural, monitoreando su rendimiento en tiempo real, validando su eficacia operativa y generando un informe final con las lecciones aprendidas y recomendaciones para futuras mejoras.

7. Plan de Ejecución y Gestión

Cronograma de Actividades

7.1. Cronograma de Actividades

| Fase | Actividad / Hito Clave | Entregable Principal | Duración Estimada (Semanas) |
|---|---|----------------------|-----------------------------|
| Fase 1: Comprensión del Negocio | <i>Definición detallada de los objetivos del proyecto, criterios de éxito y el contexto para la detección de anomalías sísmicas.</i> | 4 | |
| 1.1. Definición Detallada de Requisitos y Alcance del Proyecto | Documento de Requisitos de Negocio | 2 | |
| 1.2. Identificación de Stakeholders y Criterios de Éxito Medibles | Matriz de Criterios de Éxito del Proyecto | 2 | |
| Fase 2: Comprensión de los Datos | <i>Recopilación, exploración inicial y análisis de los conjuntos de datos sísmicos disponibles, identificando la calidad y desafíos inherentes.</i> | 8 | |
| 2.1. Recopilación y Gestión de Fuentes de Datos Sísmicos | Inventario Detallado de Datos Sísmicos | 4 | |
| 2.2. Análisis Exploratorio de Datos (EDA) y Caracterización Sísmica | Informe de Análisis Descriptivo de Datos | 4 | |
| Fase 3: Preparación de los Datos | <i>Limpieza, integración, transformación y selección de datos sísmicos, aplicando técnicas avanzadas para manejar datos limitados y heterogéneos.</i> | 12 | |

| | | | |
|--|--|-----------|--|
| 3.1. Limpieza y Preprocesamiento de Datos Sísmicos Brutos | Conjunto de Datos Limpio y Normalizado | 4 | |
| 3.2. Integración de Datos Heterogéneos y Estrategias de Aumento | Base de Datos Integrada y Aumentada | 4 | |
| 3.3. Ingeniería de Características y Creación de Conjuntos de Entrenamiento/Prueba | Conjuntos de Datos para Entrenamiento y Prueba | 4 | |
| Fase 4: Modelado | <i>Selección, diseño e implementación de algoritmos de Inteligencia Artificial, así como el entrenamiento y ajuste iterativo para la detección robusta de anomalías sísmicas y su optimización para la generalización.</i> | 24 | |
| 4.1. Diseño y Selección de Arquitecturas de Modelos de IA | Especificación de Arquitecturas de Modelos | 6 | |
| 4.2. Implementación y Entrenamiento Inicial de Modelos de Detección de Anomalías | Prototipo de Modelo de IA (v1.0) | 8 | |
| 4.3. Optimización Iterativa de Modelos para Robustez en Datos Limitados | Modelo de IA Optimizado para Precisión (>85%) | 6 | |
| 4.4. Desarrollo de Estrategias para la Generalización del Modelo | Informe de Estrategias de Generalización | 4 | |
| Fase 5: Evaluación | <i>Evaluación exhaustiva del rendimiento de los modelos desarrollados utilizando métricas clave y conjuntos de datos de validación independientes, verificando la capacidad de generalización.</i> | 20 | |
| 5.1. Evaluación de Rendimiento de Modelos en Datos de Prueba | Informe de Métricas de Rendimiento (F1-score, AUC) | 8 | |
| 5.2. Validación de Generalización en Configuraciones Geológicas Diversas | Informe de Generalización del Modelo (>80% precisión) | 8 | |
| 5.3. Refinamiento Final del Modelo Basado en Evaluación | Modelo de IA Validado (v2.0) | 4 | |

| | | | |
|--|---|-----------|--|
| Fase 6: Despliegue | <i>Implementación del sistema de detección de anomalías sísmicas basado en IA en un entorno piloto rural, monitoreando su rendimiento en tiempo real y validando su eficacia operativa.</i> | 28 | |
| 6.1. Diseño e Implementación del Entorno Piloto Rural | Plan de Despliegue del Piloto | 6 | |
| 6.2. Integración y Puesta en Marcha del Sistema en el Piloto | Sistema de Detección Operativo en Piloto | 8 | |
| 6.3. Monitoreo y Pruebas en Tiempo Real del Rendimiento Operacional | Registros de Detección y Alertas (Tasa de Falsas Alarmas <10%) | 10 | |
| 6.4. Análisis de Resultados del Piloto y Generación de Informe Final | Informe de Validación del Sistema en Piloto | 4 | |

Matriz de Riesgos

7.2. Matriz de Riesgos

| # | Riesgo Potencial | Probabilidad | Impacto | Estrategia de Mitigación |
|---|--|--------------|---------|--|
| 1 | Calidad y Disponibilidad de Datos Sísmicos <i>Relacionado con: Fase 2 (Comprensión de los Datos) y Fase 3 (Preparación de los Datos)</i> | Medium | High | Realizar un análisis de calidad de datos exhaustivo durante la Fase 2.2. Establecer acuerdos de nivel de servicio (SLA) con fuentes de datos externas. Desarrollar estrategias robustas de aumento de datos y manejo de datos faltantes en la Fase 3.2. Contar con planes de contingencia para la adquisición de fuentes de datos alternativas si las principales son insuficientes. |

| | | | | |
|---|--|--------|------|--|
| 2 | Rendimiento Insuficiente del Modelo de IA <i>Relacionado con: Fase 4 (Modelado) y Fase 5 (Evaluación)</i> | Medium | High | Implementar un enfoque iterativo para el desarrollo del modelo (Fase 4.2 y 4.3), con hitos de rendimiento claramente definidos. Explorar y comparar múltiples arquitecturas de modelos (Fase 4.1). Establecer un umbral de rendimiento mínimo aceptable y tener algoritmos de respaldo o enfoques alternativos listos para su implementación. |
| 3 | Retrasos en la Integración y Despliegue en Entorno Piloto <i>Relacionado con: Fase 6 (Despliegue)</i> | Medium | High | Realizar un diseño detallado del entorno piloto (Fase 6.1) incluyendo pruebas de compatibilidad de hardware/software. Establecer un equipo de soporte técnico dedicado para la integración y puesta en marcha (Fase 6.2). Planificar fases de prueba exhaustivas en un entorno de laboratorio antes del despliegue en campo para identificar y resolver problemas de antemano. |
| 4 | Escasez de Recursos Especializados o Rotación de Personal Clave <i>Relacionado con: Todas las fases del proyecto</i> | Medium | High | Identificar roles críticos y desarrollar planes de sucesión o capacitación cruzada para el equipo. Documentar exhaustivamente todos los procesos, decisiones y código. Mantener un banco de talentos o acuerdos con consultores externos para cubrir necesidades urgentes de personal especializado. |

| | | | | |
|---|--|--------|--------|---|
| 5 | Falsas Alarmas o Fallos de Detección en el Entorno Operacional <i>Relacionado con: Fase 6 (Despliegue)</i> | Medium | High | Durante la Fase 5 y 6, establecer métricas claras y umbrales aceptables para la tasa de falsas alarmas y la precisión de detección. Realizar pruebas piloto exhaustivas (Fase 6.3) con supervisión humana y datos reales. Implementar un mecanismo de retroalimentación continua desde el entorno piloto para el ajuste fino del modelo y los umbrales de alerta. |
| 6 | Desviación del Alcance del Proyecto (Scope Creep) <i>Relacionado con: Fase 1 (Comprensión del Negocio) y todas las fases subsiguientes</i> | Low | Medium | Establecer un control de cambios riguroso desde la Fase 1.1 y 1.2, con un proceso formal para la evaluación y aprobación de cualquier modificación. Documentar claramente el alcance del proyecto y los criterios de éxito medibles. Comunicar proactivamente el alcance definido a todos los stakeholders para gestionar las expectativas. |

8. Resultados e Impactos Esperados

8.1. Resultados Esperados (Entregables)

- **Paquete de Algoritmos y Modelos de IA Robustos:** Un conjunto de algoritmos de Inteligencia Artificial (ej., aprendizaje por transferencia, redes neuronales) y modelos entrenados, validados para la detección de anomalías sísmicas en entornos con datos sísmicos limitados y heterogéneos, con una precisión superior al 85%. (Corresponde al Objetivo Específico 1).
- **Modelos de IA Optimizados y Generalizados:** Modelos de IA optimizados que demuestran una alta capacidad de generalización para detectar anomalías sísmicas en al menos tres regiones geológicamente distintas, con una reducción del error de predicción del 20% y manteniendo una precisión superior al 80%. (Corresponde al Objetivo Específico 2).

- **Sistema Prototipo de Detección de Anomalías Sísmicas con IA Validado:** Un sistema prototipo funcional de detección de anomalías sísmicas basado en IA, implementado y operando en un entorno piloto rural, demostrando una reducción del tiempo de detección del 30% y una tasa de falsas alarmas inferior al 10%. (Corresponde al Objetivo Específico 3).

- **Informe de Validación del Sistema Piloto:** Un informe técnico detallado con los resultados de la implementación y prueba del sistema prototipo en el entorno piloto, incluyendo métricas de rendimiento en tiempo real, análisis de eficacia y recomendaciones para su escalado. (Corresponde al Objetivo Específico 3).

8.2. Impactos Esperados

- **Impacto Técnico/Científico:**

Este proyecto impulsará significativamente el estado del arte en la detección de anomalías sísmicas al desarrollar nuevas metodologías de Inteligencia Artificial específicamente adaptadas a entornos con datos sísmicos limitados y heterogéneos, un desafío persistente en la sismología. Los algoritmos y modelos optimizados no solo mejorarán la precisión y la capacidad de generalización en diversas configuraciones geológicas, sino que también establecerán un nuevo paradigma para el monitoreo sísmico en regiones tradicionalmente desatendidas, contribuyendo con conocimiento original en el campo del aprendizaje automático aplicado a las geociencias.

- **Impacto Económico:**

La implementación de un sistema de alerta temprana más preciso y rápido reducirá las pérdidas económicas asociadas a eventos sísmicos. Al proporcionar una detección de anomalías más eficiente, se facilitará una mejor planificación y respuesta ante desastres, minimizando daños a infraestructuras y propiedades. Además, el desarrollo de esta tecnología innovadora puede generar nuevas oportunidades económicas, como la creación de servicios especializados en monitoreo sísmico basado en IA y el fortalecimiento de la competitividad tecnológica en el sector de la gestión de riesgos en la región.

- **Impacto Social/Ambiental:**

El impacto social principal del proyecto radica en la mejora directa de la seguridad y resiliencia de las comunidades rurales vulnerables. Al ofrecer un sistema de alerta temprana más eficaz, se contribuirá a la reducción de víctimas y heridos, así como a una mejor preparación y capacidad de respuesta ante emergencias sísmicas. Esto fortalecerá la protección ciudadana y la confianza en los sistemas de monitoreo. Desde una perspectiva ambiental, una mejor comprensión y detección de anomalías sísmicas puede contribuir indirectamente a la gestión sostenible del territorio y a la mitigación de riesgos naturales, al proporcionar datos más precisos para el análisis de peligros geológicos.

9. Referencias Bibliográficas

Aminzadeh, F. (2003). Meta-Attributes: A New Concept for Reservoir Characterization and Seismic Anomaly Detection. En *SEG Technical Program Expanded Abstracts 2003* (pp. 520-523). Society of Exploration Geophysicists. <https://doi.org/10.1190/1.1817551>

Giunchi, C., & Sadeghian, R. (2019). Seismic Phases Recognition Based on Long Short Term Memory Networks and Anomaly Detection. *2019 18th IEEE International Conference On Machine Learning And Applications (ICMLA)*, 1269-1274. <https://doi.org/10.1109/ICMLA.2019.00204>

Infobae. (2025, 21 de julio). *El uso de inteligencia artificial revela más de 80.000 terremotos ocultos bajo la caldera de Yellowstone*. Recuperado de <https://www.infobae.com/estados-unidos/2025/07/21/el-uso-de-inteligencia-artificial-revela-80000-terremotos-ocultos-bajo-la-caldera-de-yellowstone/>

Kubo, H., Naoi, M., & Kano, M. (2024). Recent advances in earthquake seismology using machine learning. *Earth, Planets and Space*, 76(1), 22. <https://doi.org/10.1186/s40623-024-01804-0>

Lyu, Y., Wang, X., Yong, S., & Huang, J. (2019). An AETA Geo-sound Anomaly Detection Method Based on Baer Operator. *E3S Web of Conferences*, 108, 02008. <https://doi.org/10.1051/e3sconf/201910802008>

Okazaki, T. (2024). Scientific Machine Learning Seismology. *Earth, Planets and Space*, 76(1), 10. <https://doi.org/10.1186/s40623-023-01772-2>

Sriram, A., Rahnamayan, S., & Bourennani, F. (2014). Artificial Neural Networks for Earthquake Anomaly Detection. *2014 International Joint Conference on Neural Networks (IJCNN)*, 3968-3974. <https://doi.org/10.1109/IJCNN.2014.6889758>

WMO. (2023). *La inteligencia artificial aplicada a la reducción de riesgos de desastre: oportunidades, retos y consideraciones éticas*. Recuperado de <https://wmo.int/es/media/magazine-article/la-inteligencia-artificial-apli-cada-la-reduccion-de-riesgos-de-desastre-oportunidades-retos-y>

Yahoo Noticias. (2019, 11 de agosto). *La IA está cambiando nuestra comprensión de los terremotos*. Recuperado de <https://es-us.noticias.yahoo.com/ia-cambiando-comprensi%C3%B3n-terremotos-140000443.html>

Yousefpour, N., & Mojtahedi, F. F. (2023). Early detection of internal erosion in earth dams: combining seismic monitoring and convolutional AutoEncoders. *Geotechnical Research*, 10(1), 1-19. <https://doi.org/10.1680/jgers.22.00030>