



# Detección de Anomalías Sísmicas con Inteligencia Artificial

## 1. Resumen Ejecutivo

### 1. Resumen Ejecutivo

La detección temprana y precisa de anomalías sísmicas en vastas regiones geográficas, especialmente en zonas rurales con datos limitados y ruidosos, representa un desafío crítico con consecuencias devastadoras. Este proyecto aborda esta ineficacia mediante el desarrollo e implementación de un sistema avanzado de detección de anomalías sísmicas basado en inteligencia artificial, con la visión de mejorar drásticamente la precisión y la anticipación en la gestión de riesgos sísmicos en estos entornos vulnerables.

Para lograr esta visión, nuestro plan se estructura en fases clave: estableceremos una infraestructura robusta para la recolección y preprocesamiento de datos sísmicos; investigaremos, diseñaremos y optimizaremos modelos de IA adaptativos capaces de identificar patrones anómalos; integraremos estos modelos en un prototipo funcional de sistema de alerta temprana; y finalmente, validaremos y optimizaremos el sistema en un entorno piloto real. Todo esto se guiará por el framework CRISP-DM, asegurando un enfoque iterativo y estructurado.

Los resultados esperados incluyen un sistema automatizado de gestión de datos sísmicos, modelos de IA de alta precisión para la detección de anomalías, un prototipo funcional de alerta temprana y una versión final del sistema validada y optimizada para uso en campo. Estos entregables generarán un impacto técnico y científico significativo al avanzar el estado del arte en sismología, un impacto económico al reducir pérdidas y crear nuevas oportunidades, y un impacto social fundamental al mejorar la seguridad y resiliencia de las

comunidades rurales.

Este proyecto es una inversión estratégica que transformará la capacidad de anticipación y respuesta ante eventos sísmicos, protegiendo vidas y bienes en las comunidades más necesitadas.

## 2. Generalidades del Proyecto

- **Descripción:** El proyecto busca implementar un sistema para la detección de anomalías sísmicas en zonas rurales. Utilizará inteligencia artificial para identificar patrones inusuales en los datos sísmicos.
- **Palabras Clave:** Detección de Anomalías, Sísmicas, Inteligencia Artificial, Zonas Rurales

## 3. Planteamiento del Problema y Justificación

La detección de anomalías sísmicas es un campo de vital importancia en la sismología y la geofísica, fundamental para la comprensión de la dinámica terrestre y la gestión de riesgos asociados a eventos sísmicos. Sin embargo, a pesar de los avances tecnológicos, la capacidad de identificar patrones inusuales o precursores de terremotos de manera rápida y precisa, especialmente en vastas regiones geográficas, sigue siendo un desafío significativo. La ineficacia en la detección temprana y precisa de estas anomalías puede tener consecuencias devastadoras, desde la pérdida de vidas hasta daños infraestructurales masivos, representando un problema global con implicaciones económicas y sociales considerables.

Como se detalla en la sección 4.4 del Marco Teórico, a pesar de la creciente aplicación de la Inteligencia Artificial en la sismología, persisten brechas críticas en el conocimiento y la implementación efectiva. La literatura (Airlangga, 2024; Lin et al., 2025; Wang et al., 2025) demuestra la eficacia de algoritmos de Machine Learning y Deep Learning en la identificación de anomalías sísmicas y fallos instrumentales en entornos con datos relativamente estructurados y abundantes. No obstante, una limitación fundamental es la escasez de datos sísmicos etiquetados y de alta calidad en muchas regiones rurales, donde la infraestructura de monitoreo es a menudo menos densa y los datos pueden ser ruidosos o incompletos. Esta situación dificulta el entrenamiento y la validación de modelos supervisados y no supervisados, dejando un vacío tecnológico significativo para la detección de anomalías en estos contextos. Además, gran parte de la investigación se centra en eventos sísmicos conocidos, descuidando la exploración de anomalías que podrían ser precursores de terremotos o fenómenos geológicos complejos aún no bien comprendidos.

El proyecto "Detección de Anomalías Sísmicas con Inteligencia Artificial" surge como la respuesta directa y necesaria a estas limitaciones. Al implementar un sistema robusto basado en inteligencia artificial, el proyecto abordará la necesidad crítica de detectar patrones inusuales en datos sísmicos en zonas rurales. La integración de algoritmos de IA avanzados y adaptativos permitirá el procesamiento eficaz de datos limitados y ruidosos, superando las deficiencias de los métodos actuales y ofreciendo la capacidad de identificar anomalías que podrían ser indicativas tanto de fenómenos geológicos subyacentes como de posibles precursores de eventos sísmicos. Este enfoque innovador representa el siguiente paso lógico para mejorar la precisión y la anticipación en la detección sísmica en entornos desafiantes.

Este proyecto es oportuno y de importancia estratégica, ya que aborda una necesidad crítica de seguridad y resiliencia en comunidades rurales que a menudo carecen de infraestructura de monitoreo sísmico adecuada.

Su implementación no solo mejorará drásticamente la capacidad de detección de anomalías sísmicas en estas zonas, sino que también contribuirá significativamente a la gestión de riesgos y a la comprensión científica de los fenómenos sísmicos complejos. La innovación inherente a la aplicación de IA adaptativa en entornos de datos heterogéneos posiciona este proyecto como un catalizador para el desarrollo de sistemas de alerta temprana más fiables y eficientes, con un impacto transformador en la protección civil y el bienestar de las poblaciones afectadas.

## 4. Marco Teórico y Estado del Arte

### 4.1. Introducción al Dominio

La detección de anomalías sísmicas es un campo crítico en la sismología y la geofísica, centrado en la identificación de patrones inusuales o desviaciones significativas en los datos sísmicos que podrían indicar precursores de terremotos, eventos sísmicos no caracterizados, o fallos instrumentales. Tradicionalmente, este proceso ha dependido de la interpretación humana y de algoritmos basados en umbrales, lo que a menudo resulta en limitaciones de velocidad, precisión y la capacidad de procesar grandes volúmenes de datos. La irrupción de la Inteligencia Artificial (IA), particularmente el aprendizaje automático (Machine Learning, ML) y el aprendizaje profundo (Deep Learning, DL), ha revolucionado este campo al ofrecer herramientas avanzadas para el análisis de datos complejos y la identificación automatizada de patrones sutiles que escapan a los métodos convencionales.

El uso de la IA en la sismología permite no solo mejorar la eficiencia en la detección de eventos sísmicos, sino también desvelar anomalías que podrían ser indicativas de fenómenos geológicos subyacentes o de la necesidad de mantenimiento en la instrumentación. La capacidad de los algoritmos de IA para aprender de grandes conjuntos de datos y adaptarse a diferentes contextos sísmicos es particularmente valiosa, especialmente en regiones con alta actividad sísmica o en zonas rurales donde la infraestructura de monitoreo puede ser menos densa o los desafíos de recopilación de datos más pronunciados. Este enfoque promete una mejora sustancial en la gestión de riesgos sísmicos y en la comprensión de la dinámica terrestre.

### 4.2. Revisión de la Literatura (Literature Review)

La aplicación de técnicas de inteligencia artificial para la detección de anomalías sísmicas ha ganado tracción en la última década, con un enfoque creciente en el aprovechamiento de algoritmos de aprendizaje automático y profundo para mejorar la precisión y la eficiencia.

Gregorius Airlangga (2024) realizó un estudio comparativo exhaustivo de algoritmos de aprendizaje automático para la detección de anomalías en datos sísmicos en Indonesia, una región de alta sismicidad. Evaluando Local Outlier Factor (LOF), Isolation Forest y One-Class SVM, el estudio encontró que One-Class SVM y Isolation Forest mostraron un rendimiento superior en la distinción entre patrones sísmicos normales y anómalos. La metodología incluyó la estandarización de características y validación estadística, destacando la robustez de estos métodos para el manejo de datos sísmicos complejos. En un trabajo relacionado,

Airlangga (2024) profundizó en el análisis de estos algoritmos, empleando un enfoque de consenso para la detección de valores atípicos en eventos sísmicos caracterizados por latitud, longitud, profundidad y magnitud. Los hallazgos sugirieron que, aunque la mayoría de los eventos son consistentes con patrones geológicos esperados, un pequeño porcentaje exhibe un comportamiento anómalo que podría correlacionarse con características específicas del evento o ubicaciones geográficas únicas, lo que tiene implicaciones significativas para la evaluación de riesgos y los sistemas de alerta temprana.

En el ámbito del aprendizaje profundo, Lin, Aguiar, Kong, Price y Myers (2025) propusieron un modelo de autoencoder profundo, un enfoque de aprendizaje no supervisado, para la detección de anomalías en datos sísmicos con una aplicación específica en la identificación de fallos instrumentales. Este modelo evalúa la calidad de los datos sin hacer suposiciones previas sobre lo que constituye datos normales o anómalos, lo que permite identificar desviaciones que podrían indicar fallos incipientes en los instrumentos. La validación con estaciones del Sistema de Monitoreo Internacional (IMS) de EE. UU. demostró su capacidad para detectar anomalías a escala mensual, superando a los métodos de QA tradicionales y mostrando una alta transferibilidad entre redes sísmicas.

Finalmente, Wang, Saida y Nishio (2025) presentaron un enfoque novedoso para la detección de anomalías estructurales en eventos sísmicos a partir de datos de video, integrando técnicas de transferencia de aprendizaje con análisis de redes de fuerza de nodos extendidos. Aunque se centra en la integridad estructural más que en el evento sísmico en sí, este trabajo ilustra el potencial del aprendizaje profundo (utilizando modelos preentrenados como BEiT + UPerNet) para identificar regiones de interés y detectar perturbaciones en campos vectoriales no lineales, ofreciendo una solución integral para la detección de anomalías con alta precisión y fiabilidad en infraestructuras civiles. Este estudio subraya la versatilidad de las arquitecturas de aprendizaje profundo en la identificación de desviaciones del comportamiento normal en contextos relacionados con la sismología.

#### **4.3. Tecnologías y Enfoques Actuales (State of the Art)**

El estado del arte en la detección de anomalías sísmicas con inteligencia artificial se caracteriza por una convergencia de técnicas avanzadas de aprendizaje automático y profundo. Los algoritmos no supervisados, como los autoencoders, Isolation Forest y One-Class SVM, son prominentes debido a su capacidad para identificar patrones anómalos sin necesidad de datos etiquetados de antemano, lo cual es ventajoso en sismología donde los eventos anómalos son raros y difíciles de clasificar (Airlangga, 2024; Lin et al., 2025). Estos métodos son particularmente efectivos para el procesamiento de grandes volúmenes de datos sísmicos en tiempo real, mejorando drásticamente la velocidad y precisión de la detección en comparación con los análisis manuales o basados en umbrales estáticos (actualidad-ia.com, n.d.).

Las redes neuronales profundas (DNNs), incluyendo las redes convolucionales (CNNs) y los autoencoders, están siendo ampliamente adoptadas para la extracción de características complejas y la identificación de anomalías sutiles en las formas de onda sísmicas. Estas arquitecturas pueden aprender representaciones jerárquicas de los datos, lo que les permite capturar relaciones no lineales y patrones espacio-temporales que son indicativos de eventos sísmicos inusuales o precursores (es-us.noticias.yahoo.com, n.d.). Además, la integración de IA con sistemas de información geográfica (SIG) y el desarrollo de modelos predictivos que combinan datos sísmicos con otras fuentes geofísicas (geofisik.com, n.d.) representan una tendencia clave. La investigación también explora la transferibilidad de modelos entre diferentes regiones sísmicas y la

adaptabilidad a nuevos tipos de anomalías, lo que es crucial para la robustez y generalización de los sistemas de detección (Lin et al., 2025).

#### 4.4. Brechas de Conocimiento y Oportunidades (Knowledge Gaps & Opportunities)

A pesar de los avances significativos, existen varias brechas de conocimiento y oportunidades en la detección de anomalías sísmicas con inteligencia artificial, especialmente en el contexto de las zonas rurales. Una limitación fundamental es la escasez de datos sísmicos etiquetados y de alta calidad en muchas regiones rurales, lo que dificulta el entrenamiento de modelos supervisados y la validación de enfoques no supervisados. La infraestructura de monitoreo sísmico en estas áreas suele ser menos densa, lo que resulta en datos con mayor ruido o con lagunas, un desafío que los modelos actuales no siempre abordan de manera óptima (Protección Civil, n.d.; RMGIR, n.d.).

Existe una oportunidad para desarrollar modelos de IA más robustos y adaptables que puedan funcionar eficazmente con datos limitados o ruidosos, quizás mediante el uso de técnicas de aprendizaje por transferencia, aprendizaje semi-supervisado o enfoques de federated learning que permitan el entrenamiento distribuido sin centralizar datos sensibles. Además, la mayoría de la investigación se centra en la detección de eventos sísmicos conocidos o en la identificación de fallos instrumentales, dejando un espacio para la exploración de anomalías que podrían ser precursores de terremotos o fenómenos geológicos complejos aún no bien comprendidos. El proyecto propuesto, al enfocarse en la detección de anomalías sísmicas en zonas rurales, aborda directamente la necesidad de sistemas que puedan operar en entornos con recursos limitados y datos heterogéneos, ofreciendo una solución innovadora para mejorar la resiliencia y la seguridad en estas comunidades.

## 5. Objetivos

### Objetivo General

Desarrollar e implementar un sistema avanzado de detección de anomalías sísmicas basado en inteligencia artificial para mejorar la precisión y la anticipación en la gestión de riesgos en zonas rurales con datos sísmicos limitados y ruidosos.

### Objetivos Específicos

1. **Objetivo:** Establecer una infraestructura de datos sísmicos robusta.

- **Específico (S):** Diseñar, desarrollar e implementar un sistema automatizado para la recolección, limpieza y estructuración de datos sísmicos heterogéneos y ruidosos provenientes de estaciones de monitoreo en zonas rurales, asegurando su disponibilidad para el entrenamiento de modelos de IA.
- **Medible (M):** Lograr la integración y procesamiento del 80% de las fuentes de datos sísmicos identificadas en las regiones rurales objetivo, con una tasa de éxito en la limpieza de datos del 90% (reducción de ruido y completitud), medido mediante métricas de calidad de datos estándar.



- **Alcanzable (A):** Es alcanzable mediante la adaptación de técnicas existentes de ETL (Extracción, Transformación y Carga) y preprocesamiento de datos sísmicos, aplicando algoritmos de filtrado y normalización específicos para entornos ruidosos y de baja densidad.
- **Relevante (R):** Este objetivo es fundamental ya que aborda la limitación clave de la escasez y baja calidad de datos sísmicos en zonas rurales, proporcionando la base necesaria para el desarrollo y entrenamiento de los modelos de IA, contribuyendo directamente a la capacidad de detección.
- **Plazo (T):** Completado y operativo en los primeros 6 meses del proyecto.

## 2. **Objetivo:** Desarrollar y optimizar modelos de IA para la detección de anomalías.

- **Específico (S):** Investigar, diseñar y entrenar algoritmos de Machine Learning y Deep Learning adaptativos, capaces de identificar patrones anómalos en los datos sísmicos preprocesados, con un enfoque en la superación de la escasez de datos etiquetados.
- **Medible (M):** Los modelos desarrollados deberán alcanzar una precisión de detección de anomalías del 85% y una tasa de falsos positivos inferior al 10% en un conjunto de datos de validación independiente, y demostrar la capacidad de identificar al menos 3 tipos de anomalías sísmicas relevantes (e.g., precursores, fallos instrumentales, eventos atípicos).
- **Alcanzable (A):** Es factible mediante la aplicación de técnicas avanzadas de IA como el aprendizaje por transferencia, el aprendizaje auto-supervisado y el aumento de datos, que son adecuadas para entornos con datos limitados.
- **Relevante (R):** Este objetivo es el corazón del proyecto, ya que genera la capacidad tecnológica central para la detección de anomalías, abordando directamente la brecha en el conocimiento y la implementación efectiva de IA en sismología, según lo planteado en el problema.
- **Plazo (T):** Modelos desarrollados y validados en un entorno de laboratorio dentro de los 12 meses del proyecto.

## 3. **Objetivo:** Integrar y prototipar un sistema de alerta temprana.

- **Específico (S):** Integrar los modelos de IA optimizados en un prototipo de sistema funcional capaz de procesar flujos de datos sísmicos en tiempo real o casi real, generando alertas de anomalías y visualizaciones para usuarios.
- **Medible (M):** Desarrollar un prototipo de sistema que demuestre una latencia de detección y alerta inferior a 5 segundos desde la recepción del dato anómalo, y que sea capaz de procesar al menos 100 eventos sísmicos simulados por hora sin fallos. Se entregará una Interfaz de Usuario (UI) básica para la visualización de alertas.
- **Alcanzable (A):** Es realista dado que la integración de componentes de software y hardware es una práctica común en proyectos de I+D, y se pueden utilizar plataformas de desarrollo ágiles para acelerar el proceso.
- **Relevante (R):** Este objetivo transforma los modelos teóricos en una herramienta práctica y operativa, crucial para la aplicación real en la gestión de riesgos y para validar la viabilidad técnica del enfoque.

propuesto, directamente contribuyendo a la anticipación en la detección.

- **Plazo (T):** Prototipo funcional completado y probado internamente en los 15 meses del proyecto.

#### 4. **Objetivo:** Validar y optimizar el sistema en un entorno piloto.

- **Específico (S):** Desplegar el prototipo del sistema de detección de anomalías sísmicas en un entorno piloto real en una región rural seleccionada, recopilar retroalimentación de usuarios y datos de rendimiento, y realizar optimizaciones iterativas.

- **Medible (M):** Durante un período de prueba piloto de 3 meses, el sistema deberá mantener una precisión de detección del 90% y una tasa de falsos positivos por debajo del 5% en condiciones operativas reales. Se documentarán y aplicarán al menos 5 mejoras al sistema basadas en la retroalimentación del piloto y el análisis de rendimiento.

- **Alcanzable (A):** Es factible después de una fase de prototipado exitosa, permitiendo ajustar y mejorar el sistema con datos y condiciones del mundo real, lo cual es esencial para su robustez.

- **Relevante (R):** Este objetivo asegura que el sistema sea robusto, confiable y adaptado a las necesidades reales de las comunidades rurales, validando su impacto transformador en la protección civil y el bienestar de las poblaciones, como se menciona en la justificación.

- **Plazo (T):** Finalización de la fase piloto y entrega de la versión optimizada del sistema dentro de los 24 meses del proyecto.

## 6. Metodología Propuesta

**Framework Seleccionado:** CRISP-DM (Cross-Industry Standard Process for Data Mining)

El framework CRISP-DM ha sido seleccionado por su idoneidad para proyectos de investigación y desarrollo centrados en la inteligencia artificial y el análisis de datos. Este enfoque iterativo y estructurado es fundamental para abordar los desafíos inherentes a la detección de anomalías sísmicas con datos limitados y ruidosos, permitiendo una gestión sistemática desde la comprensión inicial del problema y los datos (Objetivo 1), pasando por el desarrollo y optimización de modelos de IA (Objetivo 2), hasta la integración, evaluación rigurosa y despliegue del sistema en un entorno real (Objetivos 3 y 4). Su adaptabilidad asegura que el proyecto pueda refinar continuamente las soluciones propuestas en función de los hallazgos y la retroalimentación obtenida en cada fase.

#### **Fases Principales de la Metodología:**

- **Fase 1: Comprensión del Negocio (Business Understanding)** - Se enfoca en entender a fondo los objetivos del proyecto desde una perspectiva de gestión de riesgos sísmicos, definiendo los requisitos clave y el impacto esperado del sistema de detección de anomalías.

- **Fase 2: Comprensión de los Datos (Data Understanding)** - Implica la recolección inicial de datos sísmicos, su exploración para identificar características, calidad y desafíos (como ruido o heterogeneidad), y la verificación de su relevancia para los objetivos del proyecto.

- **Fase 3: Preparación de los Datos (Data Preparation)** - Consiste en las actividades de limpieza, transformación, selección y construcción de las características a partir de los datos sísmicos brutos, asegurando que estén en un formato óptimo para el entrenamiento de los modelos de IA.
- **Fase 4: Modelado (Modeling)** - En esta fase se seleccionan, diseñan y entrenan los algoritmos de Machine Learning y Deep Learning, ajustando sus parámetros para desarrollar los modelos de detección de anomalías sísmicas.
- **Fase 5: Evaluación (Evaluation)** - Se lleva a cabo una evaluación exhaustiva de los modelos desarrollados, verificando su rendimiento, precisión y capacidad para cumplir con los objetivos específicos del proyecto en entornos controlados y de validación.
- **Fase 6: Despliegue (Deployment)** - Incluye la integración de los modelos de IA validados en un prototipo de sistema funcional, su despliegue en un entorno piloto real y la planificación para su monitoreo, mantenimiento y optimización continua.

## 7. Plan de Ejecución y Gestión

### Cronograma de Actividades

#### 7.1. Cronograma de Actividades

Fase	Actividad / Hito Clave	Entregable Principal	Duración Estimada (Semanas)
<b>Fase 1: Comprensión del Negocio</b>	<i>Establecer el alcance, objetivos y requisitos del proyecto desde la perspectiva del negocio y los stakeholders.</i>	<b>4</b>	
1.1. Definición de requisitos funcionales y no funcionales del sistema de detección.	Documento de Requisitos del Negocio (DRN)	2	
1.2. Identificación de stakeholders clave y análisis de expectativas y casos de uso.	Informe de Análisis de Stakeholders y Casos de Uso	2	
<b>Fase 2: Comprensión de los Datos</b>	<i>Recolección inicial, exploración y análisis de la calidad y características de los datos sísmicos disponibles.</i>	<b>8</b>	
2.1. Identificación y acceso a fuentes de datos sísmicos heterogéneos (estaciones, bases de datos).	Inventario de Fuentes de Datos Sísmicos	4	



2.2. Análisis exploratorio de datos (EDA) y evaluación de calidad (ruido, completitud).	Informe de Calidad de Datos Sísmicos	4	
<b>Fase 3: Preparación de los Datos</b>	<i>Limpieza, transformación, selección y estructuración de los datos sísmicos para el entrenamiento de modelos de IA.</i>	<b>12</b>	
3.1. Diseño e implementación de pipelines ETL para la recolección y limpieza automatizada de datos.	Sistema Automatizado de Preprocesamiento de Datos v1.0	6	
3.2. Desarrollo y aplicación de algoritmos de filtrado, normalización y feature engineering.	Módulos de Preprocesamiento de Datos	3	
3.3. Construcción de conjuntos de datos sísmicos limpios y estructurados para entrenamiento y validación.	Conjunto de Datos Sísmicos Preparados	3	
<b>Fase 4: Modelado</b>	<i>Diseño, entrenamiento y ajuste de algoritmos de Machine Learning y Deep Learning para la detección de anomalías.</i>	<b>24</b>	
4.1. Investigación y selección de arquitecturas de ML/DL adaptativas (e.g., autoencoders, redes recurrentes).	Informe de Arquitecturas y Estrategias de Modelado	8	
4.2. Entrenamiento inicial de modelos de IA con datos preprocesados y técnicas para datos escasos.	Modelos de IA Entrenados (versión alfa)	10	
4.3. Experimentación y ajuste de hiperparámetros de los modelos para optimizar su rendimiento.	Registros de Experimentación y Parámetros Óptimos	6	
<b>Fase 5: Evaluación</b>	<i>Evaluación rigurosa del rendimiento de los modelos desarrollados, verificando su precisión y capacidad de detección.</i>	<b>12</b>	

5.1. Diseño y ejecución de experimentos de validación de modelos utilizando conjuntos de datos independientes.	Plan de Validación de Modelos y Casos de Prueba	5	
5.2. Análisis detallado de métricas de rendimiento (precisión, falsos positivos) y capacidad de detección de anomalías.	Informe de Rendimiento y Validación de Modelos	4	
5.3. Refinamiento y optimización final de modelos basados en los resultados de la evaluación.	Modelos de IA Optimizados (versión beta)	3	
<b>Fase 6: Despliegue</b>	<i>Integración de los modelos en un prototipo funcional, despliegue en un entorno piloto y optimización continua.</i>	<b>48</b>	
6.1. Integración de modelos de IA optimizados en un prototipo de sistema funcional de alerta temprana.	Prototipo de Sistema de Alerta Temprana v1.0	6	
6.2. Desarrollo de interfaz de usuario (UI) básica y módulos para procesamiento en tiempo real y alertas.	Módulos de Interfaz y Alerta	4	
6.3. Pruebas internas exhaustivas del prototipo y verificación de latencia y capacidad de procesamiento.	Informe de Pruebas de Integración y Rendimiento	2	
6.4. Despliegue del prototipo en entorno piloto real en una región rural seleccionada y configuración.	Sistema Desplegado en Entorno Piloto	8	
6.5. Monitoreo del rendimiento del sistema en piloto y recolección de feedback de usuarios y datos reales.	Informe de Monitoreo del Piloto y Retroalimentación	12	

6.6. Optimización iterativa del sistema basada en feedback del piloto y análisis de datos de rendimiento.	Versión Optimizada del Sistema v2.0	12	
6.7. Documentación final del sistema, manuales de usuario y recomendaciones de mantenimiento.	Informe Final del Proyecto y Documentación Técnica	4	

## Matriz de Riesgos

### 7.2. Matriz de Riesgos

#	Riesgo Potencial	Probabilidad	Impacto	Estrategia de Mitigación
1	<b>Disponibilidad y Calidad de Datos Sísmicos</b> <i>Relacionado con: Fase 2: Comprensión de los Datos</i>	Medium	High	Establecer acuerdos formales con instituciones sismológicas para el acceso a datos. Realizar un análisis exhaustivo de la calidad de los datos en las etapas tempranas y desarrollar planes de contingencia para la imputación de datos faltantes o el uso de técnicas de aumento si las fuentes son insuficientes.
2	<b>El Modelo de IA no Alcanza la Precisión y Sensibilidad Requerida</b> <i>Relacionado con: Fase 4: Modelado y Fase 5: Evaluación</i>	Medium	High	Investigar y experimentar con múltiples arquitecturas de ML/DL (e.g., autoencoders, redes neuronales recurrentes, Transformers) y técnicas para datos escasos. Establecer métricas de rendimiento claras y umbrales de aceptación desde la fase de diseño, e implementar un proceso de ajuste iterativo de hiperparámetros. Considerar un enfoque híbrido si los modelos puramente de IA no son suficientes.
3	<b>Retrasos en la Integración y Despliegue del Prototipo en Entorno Piloto</b> <i>Relacionado con: Fase 6: Despliegue</i>	Medium	High	Realizar pruebas de integración continuas y rigurosas desde el inicio de la Fase 6. Desarrollar un plan de despliegue detallado con hitos y responsabilidades claras. Mantener una comunicación constante y fluida con los responsables del sitio piloto para anticipar y resolver problemas técnicos o logísticos de manera proactiva.
4	<b>Complejidad en el Preprocesamiento de Datos Sísmicos Heterogéneos</b> <i>Relacionado con: Fase 3: Preparación de los Datos</i>	High	Medium	Diseñar una arquitectura de pipeline ETL modular y escalable, capaz de manejar diversas fuentes y formatos de datos sísmicos. Utilizar herramientas de orquestación de datos robustas y dedicar recursos significativos a la fase de diseño, desarrollo y pruebas del sistema de preprocesamiento.

5	<b>Bajo Rendimiento o Falsas Alarmas en el Entorno Piloto Real</b> <i>Relacionado con: Fase 6: Despliegue</i>	Medium	High	Implementar un sistema de monitoreo robusto y en tiempo real para el prototipo desplegado, recolectando métricas de rendimiento y feedback de usuarios. Establecer un ciclo de optimización iterativa basado en los datos del piloto para ajustar los umbrales de detección y refinar los modelos de IA de forma continua.
6	<b>Falta de Adopción o Resistencia del Usuario Final en el Piloto</b> <i>Relacionado con: Fase 6: Despliegue</i>	Low	Medium	Involucrar a los usuarios finales y stakeholders clave desde las fases tempranas del proyecto para entender sus necesidades y expectativas. Realizar sesiones de capacitación y demostraciones interactivas del prototipo. Establecer un canal de retroalimentación claro y continuo durante la fase piloto para abordar inquietudes y mejorar la usabilidad del sistema.

## 8. Resultados e Impactos Esperados

### #### 8.1. Resultados Esperados (Entregables)

- **Sistema de Gestión de Datos Sísmicos:** Un sistema automatizado y robusto para la recolección, limpieza y estructuración de datos sísmicos heterogéneos y ruidosos de zonas rurales, operacional y disponible para el entrenamiento de modelos de IA, correspondiente al Objetivo Específico 1.
- **Modelos de IA Optimizados para Detección de Anomalías:** Conjunto de algoritmos de Machine Learning y Deep Learning entrenados y validados, capaces de identificar patrones anómalos en datos sísmicos con alta precisión, incluyendo al menos 3 tipos de anomalías relevantes, correspondiente al Objetivo Específico 2.
- **Prototipo Funcional de Sistema de Alerta Temprana:** Un prototipo de software integrado que procesa flujos de datos sísmicos en tiempo real, genera alertas de anomalías y ofrece visualizaciones a través de una Interfaz de Usuario (UI) básica, correspondiente al Objetivo Específico 3.
- **Sistema de Detección de Anomalías Sísmicas Validado y Optimizado:** La versión final del sistema, robusta y adaptada a las necesidades reales de las comunidades rurales, validada en un entorno piloto y con mejoras implementadas basadas en la retroalimentación, correspondiente al Objetivo Específico 4.
- **Informe Técnico de Validación Piloto:** Documentación detallada de los resultados de la fase piloto, incluyendo métricas de rendimiento, retroalimentación de usuarios y un plan de mejoras futuras, correspondiente al Objetivo Específico 4.

### #### 8.2. Impactos Esperados

- **Impacto Técnico/Científico:**

El proyecto avanzará significativamente el estado del arte en la sismología y la aplicación de la inteligencia artificial para la gestión de riesgos sísmicos, particularmente en entornos con datos limitados y ruidosos. Se generarán nuevas metodologías para el preprocesamiento de datos sísmicos y el entrenamiento de modelos de IA en condiciones desafiantes, superando las limitaciones actuales. Esto resultará en una mayor precisión y capacidad de anticipación en la detección de anomalías sísmicas, sentando las bases para futuras investigaciones y desarrollos tecnológicos en el campo.

- **Impacto Económico:**

La mejora en la precisión y anticipación de la detección de anomalías sísmicas conducirá a una reducción significativa de las pérdidas económicas asociadas a eventos sísmicos. Al permitir una gestión de riesgos más eficiente y una mejor preparación, se minimizarán los daños a infraestructuras y propiedades, y se optimizará la asignación de recursos para la respuesta a emergencias. Además, el desarrollo de un sistema innovador podría generar nuevas oportunidades de negocio y servicios especializados en monitoreo sísmico y consultoría de riesgos para regiones con características similares, impulsando la competitividad tecnológica local.

- **Impacto Social/Ambiental:**

El impacto social principal radicará en la mejora sustancial de la seguridad y el bienestar de las poblaciones rurales, a menudo las más vulnerables ante eventos sísmicos debido a la escasez de infraestructura y sistemas de alerta. Al proporcionar una mayor anticipación y fiabilidad en la detección de anomalías, el sistema permitirá a las comunidades y autoridades tomar medidas preventivas más efectivas, reduciendo la pérdida de vidas y lesiones. Esto fomentará una mayor resiliencia comunitaria y confianza en los sistemas de protección civil. Indirectamente, al proteger infraestructuras críticas, se pueden mitigar riesgos ambientales asociados a fallas o daños en instalaciones industriales o de manejo de recursos.

## 9. Referencias Bibliográficas

Airlangga, G. (2024). *ADVANCED MACHINE LEARNING TECHNIQUES FOR SEISMIC ANOMALY DETECTION IN INDONESIA: A COMPARATIVE STUDY OF LOF, ISOLATION FOREST, AND ONE-CLASS SVM*. [Título del trabajo de investigación].

Airlangga, G. (2024). *ANALYSIS OF MACHINE LEARNING ALGORITHMS FOR SEISMIC ANOMALY DETECTION IN INDONESIA: UNVEILING PATTERNS IN THE PACIFIC RING OF FIRE*. [Título del trabajo de investigación].

actualidad-ia.com. (n.d.). *La IA Revoluciona la Detección Sísmica: Una 'Visión Clara'...* Recuperado de <https://actualidad-ia.com/articulos/ciencia/ia-revoluciona-deteccion-sismica-vision-clara>

es-us.noticias.yahoo.com. (n.d.). *La IA está cambiando nuestra comprensión de los terremotos*. Recuperado de <https://es-us.noticias.yahoo.com/ia-cambiando-comprensi%C3%B3n-terremotos-140000443.html>

geofisik.com. (n.d.). *Tendencias 2025: Integración de IA y machine learning en la interpretación geofísica*. Recuperado de <https://geofisik.com/blog/innovacion-tecnologica/tendencias-2025-integracion-ia-machine-learning-interpretacion-geofisica/>

Lin, J.-T., Aguiar, A. C., Kong, Q., Price, A. C., & Myers, S. C. (2025). *Anomaly Detection in Seismic Data with Deep Learning: Application for Instrument Failure Detection and Forecasting*. [Título del trabajo de investigación].

Protección Civil. (n.d.). *Sismos*. Recuperado de [http://www.proteccioncivil.gob.mx/work/models/ProteccionCivil/Resource/377/1/images/folleto\\_s.pdf](http://www.proteccioncivil.gob.mx/work/models/ProteccionCivil/Resource/377/1/images/folleto_s.pdf)

RMGIR. (n.d.). *Estrategias para la reducción del riesgo sísmico en México*. Recuperado de <https://rmgir.proyectosamerica.org/MemoriaPropuestaComun/EstrategiasParaReduccionDeRiesgoSismicoEnMexico.pdf>

Wang, S., Saida, T., & Nishio, M. (2025). Optical Flow-Based Structural Anomaly Detection in Seismic Events From Video Data Combined With Computational Cost Reduction Through Deep Learning. [Título del trabajo de investigación].