

Detección Inteligente de Amenazas Agrícolas con Drones en Fincas Cafeteras del Quindío

CONVOCATORIA COLOMBIA INTELIGENTE: CIENCIA Y TECNOLOGÍAS
CUÁNTICAS E INTELIGENCIA ARTIFICIAL PARA LOS TERRITORIOS |
Convocatoria 966

Tabla de Contenido

1. Generalidades del Proyecto	3
2. Resumen Ejecutivo	3
3. Planteamiento del Problema y Justificación	4
4. Marco Teórico y Estado del Arte	5
4.1. <i>Introducción al Dominio</i>	5
4.2. <i>Revisión de la Literatura (Literature Review)</i>	5
4.3. <i>Tecnologías y Enfoques Actuales (State of the Art)</i>	6
4.4. <i>Brechas de Conocimiento y Oportunidades (Knowledge Gaps & Opportunities)</i>	7
5. Objetivos	7
6. Metodología Propuesta	9
7. Plan de Ejecución y Gestión	10
7.1. <i>Cronograma de Actividades</i>	10
7.2. <i>Matriz de Riesgos</i>	12
8. Resultados e Impactos Esperados	13
8.1. <i>Resultados Esperados (Entregables)</i>	13
8.2. <i>Impactos Esperados</i>	14
9. Referencias Bibliográficas	15

1. Generalidades del Proyecto

Título: Detección Inteligente de Amenazas Agrícolas con Drones en Fincas Cafeteras del Quindío

Convocatoria: CONVOCATORIA COLOMBIA INTELIGENTE: CIENCIA Y TECNOLOGÍAS CUÁNTICAS E INTELIGENCIA ARTIFICIAL PARA LOS TERRITORIOS | Convocatoria 966

Programa: Por definir

Entidad/Persona: COTECMAR

Línea Temática: Inteligencia Artificial, Tecnologías Cuánticas, CTel, Territorios, Innovación Disruptiva

Duración: Por definir

Área OCDE: Por definir

● **Descripción:** La falta de acceso a diagnósticos rápidos y especializados amenaza la sostenibilidad de cultivos clave en pequeñas fincas rurales. Este proyecto desarrollará un sistema de visión artificial, utilizando redes neuronales convolucionales, para analizar imágenes multiespectrales capturadas por drones de bajo costo y detectar enfermedades o deficiencias nutricionales en etapas tempranas. La solución será implementada y validada en fincas de pequeños productores del departamento del Quindío, en colaboración con asociaciones cafeteras locales. Se busca optimizar la gestión de cultivos, reducir pérdidas por plagas y enfermedades hasta en un 25%, y mejorar la seguridad alimentaria regional.

● **Palabras Clave:** Inteligencia Artificial, Visión Artificial, Drones Agrícolas, Agricultura de Precisión, Café, Quindío

2. Resumen Ejecutivo

La agricultura moderna en el Quindío enfrenta el desafío crítico de la falta de diagnósticos rápidos y especializados para la detección temprana de enfermedades y deficiencias nutricionales en pequeñas fincas cafeteras, resultando en pérdidas significativas. Este proyecto innovador aborda esta brecha desarrollando e implementando un sistema inteligente de visión artificial, basado en drones de bajo costo y técnicas de Inteligencia Artificial, con el fin de mejorar drásticamente la productividad y la sostenibilidad de los cultivos de café en la región. Nuestra visión es transformar la caficultura local mediante tecnología de vanguardia.

Para lograrlo, nuestro plan estratégico se articula en el diseño y desarrollo de un prototipo de visión artificial con redes neuronales convolucionales, la adquisición y curación de un robusto conjunto de datos multiespectrales de fincas del Quindío, la validación rigurosa del sistema en condiciones reales de campo, y un programa integral de transferencia de conocimiento y capacitación a los productores. La metodología seleccionada, el Modelo en V de Ingeniería de Sistemas, garantiza un enfoque estructurado y una validación exhaustiva en cada fase del proyecto.

El éxito de este proyecto se traducirá en un prototipo funcional con una precisión superior al 90% en entornos controlados y un sistema validado en campo con un 85% de exactitud, respaldado por una base de datos multiespectral única. Los impactos esperados son profundos: una reducción de hasta el 25% en las pérdidas de cosecha, un aumento en la rentabilidad de los pequeños caficultores y una notable mejora en la sostenibilidad ambiental mediante la optimización del uso de agroquímicos. Además, empoderaremos a los productores, cerrando la brecha digital y fomentando la toma de decisiones informadas.

Este proyecto no solo es una respuesta tecnológica oportuna, sino una iniciativa estratégica esencial para asegurar la resiliencia económica y la sostenibilidad futura de la caficultura en el Quindío, posicionando a la región como un referente en la agricultura de precisión.

3. Planteamiento del Problema y Justificación

La agricultura moderna está experimentando una profunda transformación impulsada por la integración de tecnologías avanzadas como la Inteligencia Artificial y la Visión Artificial en el marco de la Agricultura de Precisión. Sin embargo, a pesar de estos avances tecnológicos, la sostenibilidad de cultivos clave, especialmente en pequeñas fincas rurales, se ve gravemente amenazada por la persistente falta de acceso a diagnósticos rápidos y especializados para la detección temprana de enfermedades y deficiencias nutricionales. Esta situación resulta en pérdidas significativas de productividad y calidad, afectando directamente la viabilidad económica de los pequeños productores. Como la revisión de la literatura y el análisis del estado del arte indican, la integración de la Inteligencia Artificial y los drones en la agricultura de precisión ha generado avances significativos en el monitoreo de cultivos y la detección de enfermedades (Daraojimba et al., 2024; De Silva y Brown, 2023; Hamila et al., 2023; Husnain et al., 2024; Gani et al., 2025). No obstante, persiste una brecha crítica en la disponibilidad de soluciones personalizadas y validadas para cultivos específicos y contextos agroecológicos diversos, como el café en las fincas de pequeños productores de regiones como el Quindío. La investigación existente se ha centrado predominantemente en cultivos extensivos o entornos controlados, lo que limita la generalización de los modelos a la variabilidad intrínseca de las pequeñas fincas. Esto subraya una significativa brecha tecnológica y de conocimiento en la adaptación de estas herramientas avanzadas a las necesidades y recursos limitados de los caficultores locales, dejando desatendida la especificidad de las enfermedades y deficiencias nutricionales del café en estas condiciones. Este proyecto, "Detección Inteligente de Amenazas Agrícolas con Drones en Fincas Cafeteras del Quindío", emerge como la respuesta directa e innovadora a esta brecha identificada. Al desarrollar un sistema de visión artificial basado en redes neuronales convolucionales para analizar imágenes multiespectrales capturadas por drones de bajo costo, la propuesta aborda de manera frontal la necesidad de diagnósticos rápidos y precisos. La integración de estas tecnologías permitirá la detección temprana de enfermedades o deficiencias nutricionales en el cultivo del café, superando las limitaciones de los enfoques actuales que no están optimizados para las particularidades de las pequeñas fincas cafeteras. El proyecto no solo es una buena idea, sino el paso necesario para llevar la agricultura de precisión a un segmento de productores que más lo necesita. La relevancia estratégica de este proyecto es incuestionable, dada la importancia económica y social del café para el departamento del Quindío y la vulnerabilidad de sus pequeños productores. Es un proyecto oportuno y crítico que busca mitigar las amenazas que comprometen la sostenibilidad de un pilar económico regional. Al optimizar la gestión de cultivos, se espera una reducción de pérdidas por plagas y enfermedades de hasta un 25%, lo que tendrá un impacto directo en la mejora de la seguridad alimentaria.

regional y la resiliencia económica de las fincas. Este enfoque innovador, centrado en la validación en campo real y la colaboración con asociaciones locales, posiciona al proyecto como un motor clave para la transformación digital y sostenible de la caficultura en la región.

4. Marco Teórico y Estado del Arte

4.1. Introducción al Dominio

La agricultura moderna se encuentra en una fase de transformación impulsada por la integración de tecnologías avanzadas, en particular la Inteligencia Artificial (IA) y la Visión Artificial, en el paradigma de la Agricultura de Precisión. La Inteligencia Artificial se define como la capacidad de las máquinas para imitar y ejecutar procesos cognitivos humanos, como el aprendizaje, la resolución de problemas y la toma de decisiones, aplicados en este el paradigma de la Agricultura de Precisión. La Inteligencia Artificial se define como la capacidad de las máquinas para imitar y ejecutar procesos cognitivos humanos, como el aprendizaje, la resolución de problemas y la toma de decisiones, aplicados en este contexto a la optimización de prácticas agrícolas (Daraojimba et al., 2024). La Visión Artificial, un subcampo de la IA, permite a las computadoras "ver" e interpretar imágenes y videos, lo que es fundamental para el monitoreo automatizado de cultivos y la detección de anomalías (Unitxlab, n.d.).

La Agricultura de Precisión, por su parte, es una estrategia de gestión que utiliza tecnologías de la información para recopilar datos espaciales y temporales, con el fin de optimizar el uso de recursos y maximizar la productividad de los cultivos. Dentro de este marco, los vehículos aéreos no tripulados (drones) equipados con sensores multiespectrales han emergido como herramientas invaluables. Estos drones permiten la captura de imágenes de alta resolución que revelan información sobre la salud de las plantas no visible al ojo humano, facilitando la detección temprana de enfermedades y deficiencias nutricionales (rpas-drones.com, n.d.). El presente proyecto se enmarca en este dominio, buscando aplicar estos avances para la detección inteligente de amenazas agrícolas en fincas cafeteras, un cultivo de vital importancia económica y social en regiones como el Quindío.

4.2. Revisión de la Literatura (Literature Review)

La integración de la Inteligencia Artificial y los drones en la agricultura de precisión ha sido un campo de investigación prolífico en los últimos años. **Daraojimba et al. (2024)** ofrecen una revisión exhaustiva sobre la IA en la agricultura de precisión, destacando su papel transformador en la sostenibilidad y optimización de las prácticas agrícolas. El estudio sintetiza los avances en aplicaciones de IA, incluyendo el monitoreo de cultivos, la gestión de recursos y los sistemas de apoyo a la decisión, subrayando cómo el aprendizaje automático, la visión por computadora y las tecnologías de sensores están redefiniendo los métodos agrícolas tradicionales al proporcionar datos en tiempo real e información procesable para los agricultores.

En el ámbito específico de la detección de enfermedades vegetales utilizando técnicas avanzadas, **De Silva y Brown (2023)** exploran enfoques híbridos de redes neuronales convolucionales (CNN) y Vision Transformers (ViT) para la detección multiespectral de enfermedades en plantas. Su investigación demuestra cómo la combinación de estas arquitecturas de aprendizaje profundo puede mejorar significativamente la precisión en

la identificación de enfermedades, utilizando un conjunto de datos multiespectral recolectado meticulosamente. El estudio resalta la importancia de los conjuntos de datos equilibrados y la selección adecuada de longitudes de onda para una identificación robusta de enfermedades, lo que es directamente relevante para la captura de imágenes multiespectrales con drones.

Complementariamente, **Hamila et al. (2023)** desarrollaron aplicaciones automatizadas basadas en redes neuronales convolucionales tridimensionales (3D CNNs) para la detección de la fusariosis de la espiga en trigo. Utilizando nubes de puntos 3D con cuatro canales de color (RGB y NIR), lograron una precisión del 100% en la detección de síntomas, y buenos resultados en la estimación de la severidad. Aunque se enfocaron en el trigo, su metodología para el análisis de datos multiespectrales 3D y el uso de CNNs avanzadas proveen una base sólida para la detección de enfermedades en otros cultivos.

Dirigiéndose a cultivos perennes, **Husnain et al. (2024)** investigaron el uso de imágenes multiespectrales capturadas por drones, combinadas con técnicas de aprendizaje profundo y visión por computadora, para la detección de enfermedades en árboles de mango. Su sistema propuesto utiliza modelos pre-entrenados de CNN como YOLOv5, Detectron2 y Faster R-CNN, y emplea técnicas de aumento de datos para mejorar la precisión. Este trabajo es particularmente relevante, ya que el café, al ser un cultivo perenne, presenta desafíos similares en términos de monitoreo aéreo y detección temprana de enfermedades en grandes extensiones. De manera similar, **Gani et al. (2025)** introdujeron PapayaNet, una red convolucional ligera guiada por atención para la clasificación automatizada de seis estados de hojas de papaya, incluyendo enfermedades. Este modelo, diseñado para despliegue en sistemas de borde y drones, logró una alta precisión con baja latencia, destacando la viabilidad de soluciones optimizadas para entornos agrícolas con recursos limitados.

4.3. Tecnologías y Enfoques Actuales (State of the Art)

El estado del arte en la detección inteligente de amenazas agrícolas se caracteriza por la convergencia de diversas tecnologías avanzadas. Los **drones agrícolas** son el pilar fundamental para la recopilación de datos, permitiendo el monitoreo aéreo de grandes extensiones de terreno con una frecuencia y resolución sin precedentes. Estos drones suelen estar equipados con **sensores multiespectrales**, capaces de capturar bandas de luz más allá del espectro visible (como el infrarrojo cercano), lo que permite evaluar parámetros biofísicos de las plantas, como el contenido de clorofila, la turgencia del agua y el estrés fisiológico, indicadores clave de enfermedades o deficiencias nutricionales antes de que sean evidentes a simple vista.

La **Visión Artificial** y el **Aprendizaje Profundo**, en particular las **Redes Neuronales Convolucionales (CNNs)**, constituyen el núcleo de los sistemas de análisis. Modelos como YOLO (You Only Look Once), Detectron2 y Faster R-CNN, así como arquitecturas personalizadas (e.g., PapayaNet de Gani et al., 2025), son ampliamente utilizados para la detección y clasificación de objetos (en este caso, síntomas de enfermedades o deficiencias) en las imágenes capturadas. La capacidad de las CNNs para aprender características complejas directamente de los datos de imagen las hace idóneas para identificar patrones sutiles asociados a las amenazas agrícolas. Los avances incluyen el uso de arquitecturas híbridas (CNN-ViT) para mejorar la precisión (De Silva & Brown, 2023) y la aplicación de CNNs 3D para análisis más complejos de datos multiespectrales (Hamila et al., 2023).

Además, existe una tendencia hacia el **procesamiento en tiempo real** y la implementación en **sistemas de borde (edge computing)**. Esto implica que el análisis de las imágenes se realiza directamente en el dron o en dispositivos cercanos al campo, reduciendo la latencia y permitiendo una respuesta más rápida a las amenazas detectadas. La recopilación de grandes volúmenes de datos y el uso de **técnicas de aumento de datos y redes generativas antagónicas (GANs)** son prácticas comunes para mejorar la robustez y generalización de los modelos de IA, especialmente cuando los conjuntos de datos de enfermedades son limitados o desequilibrados (Husnain et al., 2024). Estos enfoques permiten una gestión más eficiente de los cultivos, optimizando el uso de insumos y minimizando las pérdidas.

4.4. Brechas de Conocimiento y Oportunidades (Knowledge Gaps & Opportunities)

A pesar de los significativos avances en la aplicación de la IA y los drones en la agricultura de precisión, persisten varias brechas de conocimiento y oportunidades que el presente proyecto busca abordar. Una limitación clave es la **falta de soluciones personalizadas y validadas para cultivos específicos y contextos agroecológicos diversos**, como el café en fincas de pequeños productores en regiones como el Quindío. Gran parte de la investigación se centra en cultivos extensivos o en entornos controlados, y los modelos desarrollados a menudo no se generalizan bien a la variabilidad intrínseca de fincas pequeñas, con diferentes variedades de café, prácticas de manejo y condiciones microclimáticas. La especificidad de las enfermedades y deficiencias nutricionales del café, junto con los patrones de su manifestación en imágenes multiespectrales, requiere investigación y desarrollo focalizados.

Otra brecha importante es la **accesibilidad y la adopción de estas tecnologías por parte de pequeños agricultores**. Si bien existen sistemas avanzados, su costo, complejidad de operación y la necesidad de infraestructura tecnológica limitan su implementación en contextos rurales con recursos limitados. Esto genera una oportunidad para desarrollar un sistema de bajo costo, fácil de usar y diseñado específicamente para las necesidades de los caficultores del Quindío, que pueda integrarse de manera efectiva en sus prácticas agrícolas existentes. Finalmente, la **validación en campo real** en las condiciones específicas de las fincas cafeteras del Quindío es crucial. Muchos estudios demuestran la viabilidad técnica en entornos de investigación, pero la robustez y eficacia en condiciones operacionales reales, con la variabilidad inherente del terreno, la iluminación y la dinámica de las plagas y enfermedades, aún necesitan ser rigurosamente evaluadas y demostradas.

5. Objetivos

Objetivo General

Desarrollar e implementar un sistema de visión artificial inteligente, basado en drones de bajo costo y técnicas de inteligencia artificial, para la detección temprana y precisa de enfermedades y deficiencias nutricionales en cultivos de café, con el fin de mejorar la productividad y sostenibilidad de las pequeñas fincas cafeteras en el departamento del Quindío.

Objetivos Específicos

1. **Objetivo:** Diseño y Desarrollo del Sistema de Visión Artificial.

-
- **Específico (S):** Diseñar y desarrollar un sistema prototipo de visión artificial utilizando redes neuronales convolucionales (CNNs) para analizar imágenes multiespectrales capturadas por drones, capaz de identificar y clasificar al menos 3 enfermedades comunes y 2 deficiencias nutricionales específicas del cultivo de café.
 - **Medible (M):** Completar la arquitectura del software y el prototipo funcional del sistema de visión artificial. Lograr una precisión de identificación y clasificación de amenazas en un entorno controlado (pruebas de laboratorio) superior al 90%. Entregar la documentación técnica del diseño del sistema.
 - **Alcanzable (A):** Es realista dada la madurez de las tecnologías de IA y visión artificial, y la experiencia esperada del equipo de investigación en desarrollo de software y aprendizaje automático. Se basará en librerías y frameworks existentes.
 - **Relevante (R):** Este objetivo es fundamental ya que sienta las bases tecnológicas para la detección inteligente de amenazas, abordando directamente la "brecha tecnológica y de conocimiento" y la necesidad de un "sistema de visión artificial basado en redes neuronales convolucionales".
 - **Plazo (T):** Dentro de los primeros 8 meses del proyecto.

2. Objetivo: Adquisición y Curación de Datos Multiespectrales.

- **Específico (S):** Establecer y ejecutar una metodología estandarizada para la adquisición de un conjunto de datos robusto de imágenes multiespectrales de cultivos de café en fincas seleccionadas del Quindío, utilizando drones de bajo costo, y realizar la curación y etiquetado de este dataset con la validación de expertos agrónomos.
- **Medible (M):** Recopilar un mínimo de 5,000 imágenes multiespectrales georreferenciadas de plantas de café, cubriendo al menos las 3 enfermedades y 2 deficiencias nutricionales objetivo. Asegurar que el 100% de las imágenes relevantes estén etiquetadas y validadas por al menos dos expertos agrónomos independientes. Documentar los protocolos de vuelo y adquisición de datos.
- **Alcanzable (A):** Es viable con la colaboración de los caficultores locales y el uso de drones comerciales de bajo costo. La experiencia en la recolección de datos y el soporte de agrónomos locales harán posible esta tarea.
- **Relevante (R):** Este objetivo es crítico para entrenar y validar los modelos de IA del sistema de visión artificial, asegurando que el sistema sea relevante y preciso para las condiciones agroecológicas específicas del café en el Quindío, abordando la "variabilidad intrínseca de las pequeñas fincas".
- **Plazo (T):** Dentro de los primeros 12 meses del proyecto.

3. Objetivo: Validación en Campo y Optimización del Sistema.

- **Específico (S):** Implementar y validar el sistema de detección inteligente de amenazas en condiciones reales de campo en al menos 3 fincas cafeteras representativas del Quindío, recopilando retroalimentación de los usuarios y optimizando el rendimiento del sistema en función de los resultados.

- **Medible (M):** Demostrar una precisión de detección en campo del 85% para las amenazas identificadas. Reducir los falsos positivos y negativos en un 15% respecto a las pruebas iniciales en campo. Generar informes de diagnóstico detallados para cada finca validada. Recopilar al menos 15 encuestas de satisfacción de usuarios/caficultores.
- **Alcanzable (A):** Es realista una vez que el prototipo inicial y el dataset estén listos. La colaboración con asociaciones locales y caficultores facilitará el acceso a los campos y la retroalimentación.
- **Relevante (R):** Este objetivo es esencial para asegurar la viabilidad y utilidad práctica del sistema en el entorno real de los pequeños productores, validando la solución "personalizada y validada para cultivos específicos y contextos agroecológicos diversos", y contribuyendo directamente a la "reducción de pérdidas por plagas y enfermedades de hasta un 25%".
- **Plazo (T):** Dentro de los meses 13 a 18 del proyecto.

4. **Objetivo:** Transferencia de Conocimiento y Capacitación a Productores.

- **Específico (S):** Desarrollar y ejecutar un programa de capacitación dirigido a pequeños caficultores y personal técnico de asociaciones locales en el Quindío, enfocado en el uso y la interpretación de los diagnósticos generados por el sistema de detección de amenazas.
- **Medible (M):** Capacitar a un mínimo de 30 caficultores y/o técnicos. Realizar al menos 3 talleres de capacitación. Lograr que el 70% de los participantes demuestren la capacidad de interpretar los informes del sistema y tomar decisiones informadas para la gestión de cultivos. Obtener una calificación promedio de satisfacción del curso de 4.0/5.0.
- **Alcanzable (A):** Es factible mediante la colaboración con las asociaciones de caficultores existentes en la región y la creación de material didáctico claro y práctico.
- **Relevante (R):** Este objetivo garantiza la apropiación y el uso efectivo de la tecnología por parte de los beneficiarios finales, maximizando el impacto del proyecto en la "transformación digital y sostenible de la caficultura" y la "resiliencia económica de las fincas".
- **Plazo (T):** Dentro de los meses 19 a 24 del proyecto.

6. Metodología Propuesta

Framework Seleccionado: Modelo en V de Ingeniería de Sistemas

El Modelo en V de Ingeniería de Sistemas ha sido seleccionado como la metodología principal debido a la naturaleza del proyecto, que combina el desarrollo de un sistema de visión artificial basado en inteligencia artificial (software) con la integración de plataformas de adquisición de datos (drones) y su validación en un entorno real. Esta metodología garantiza un enfoque estructurado y riguroso, donde cada fase de desarrollo tiene una fase de prueba correspondiente, asegurando la trazabilidad de los requisitos y la calidad del producto final. Su énfasis en la verificación temprana y la validación en campo es crucial para cumplir los objetivos de precisión y fiabilidad del sistema de detección de amenazas agrícolas (Objetivos 1 y 3), así como para la integración efectiva de la adquisición de datos multiespectrales (Objetivo 2).

Fases Principales de la Metodología:

- **Fase 1: Análisis y Definición de Requisitos** - Se establecerán los requisitos detallados del sistema de visión artificial, los protocolos de adquisición de datos con drones, las métricas de rendimiento esperadas y las necesidades de los usuarios finales, derivando especificaciones técnicas claras.
- **Fase 2: Diseño de la Arquitectura y Componentes** - Se diseñará la arquitectura general del sistema, incluyendo la selección de tecnologías de IA (CNNs), el diseño de la base de datos de imágenes, los módulos de procesamiento de datos y la interfaz de usuario, así como los planes para la adquisición de datos.
- **Fase 3: Implementación y Desarrollo de Módulos** - Se procederá con la codificación de los algoritmos de inteligencia artificial, el desarrollo de los módulos de procesamiento de imágenes, la integración de las herramientas de adquisición de datos y la creación del prototipo funcional del sistema.
- **Fase 4: Pruebas Unitarias y de Integración** - Se realizarán pruebas exhaustivas de cada componente individual (pruebas unitarias) y de la interacción entre ellos (pruebas de integración) para asegurar que funcionen correctamente según las especificaciones de diseño.
- **Fase 5: Pruebas de Sistema y Validación en Campo** - Se verificará el sistema completo contra los requisitos definidos en la Fase 1, realizando pruebas en entornos controlados y, fundamentalmente, validaciones en condiciones reales en fincas cafeteras para evaluar su precisión y robustez operativa (Objetivo 3).
- **Fase 6: Despliegue, Optimización y Transferencia de Conocimiento** - Una vez validado, el sistema será optimizado con base en la retroalimentación de campo, desplegado para uso final, y se ejecutará el programa de capacitación y transferencia de conocimiento a los caficultores (Objetivo 4).

7. Plan de Ejecución y Gestión

Cronograma de Actividades

7.1. Cronograma de Actividades

Fase	Actividad / Hito Clave	Entregable Principal	Duración Estimada (Semanas)
Fase 1: Análisis y Definición de Requisitos	<i>Se establecerán los requisitos detallados del sistema de visión artificial, los protocolos de adquisición de datos con drones, las métricas de rendimiento esperadas y las necesidades de los usuarios finales, derivando especificaciones técnicas claras.</i>		8
	1.1. Levantamiento y análisis de requisitos funcionales y no funcionales.	Documento de Requisitos del Sistema (DRS)	4

	1.2. Definición de protocolos de vuelo y adquisición de datos multiespectrales.	Protocolo de Vuelo y Adquisición de Datos	2
	1.3. Establecimiento de métricas de rendimiento y criterios de validación en campo.	Criterios de Validación y Métricas de Rendimiento	2
Fase 2: Diseño de la Arquitectura y Componentes	<i>Se diseñará la arquitectura general del sistema, incluyendo la selección de tecnologías de IA (CNNs), el diseño de la base de datos de imágenes, los módulos de procesamiento de datos y la interfaz de usuario.</i>		12
	2.1. Diseño de la arquitectura general del sistema de visión artificial.	Documento de Arquitectura del Sistema	5
	2.2. Diseño detallado de modelos de CNN y módulos de procesamiento de imágenes.	Especificaciones de Diseño de CNNs y Módulos	4
	2.3. Diseño de la base de datos de imágenes y la interfaz de usuario prototipo.	Diseño de Base de Datos e Interfaz de Usuario Prototipo	3
Fase 3: Implementación y Desarrollo de Módulos	<i>Se procederá con la codificación de los algoritmos de inteligencia artificial, el desarrollo de los módulos de procesamiento de imágenes, la integración de las herramientas de adquisición de datos y la creación del prototipo funcional del sistema.</i>		12
	3.1. Codificación e implementación de algoritmos de CNN para detección y clasificación.	Módulos de CNN Implementados	5
	3.2. Desarrollo de módulos de procesamiento de imágenes y la base de datos.	Módulos de Procesamiento y BD Desarrollados	4
	3.3. Integración de herramientas para adquisición y pre-procesamiento de datos.	Herramientas de Adquisición/Pre-procesamiento Integradas	3
Fase 4: Pruebas Unitarias y de Integración	<i>Se realizarán pruebas exhaustivas de cada componente individual (pruebas unitarias) y de la interacción entre ellos (pruebas de integración). Se iniciará la adquisición y curación masiva de datos multiespectrales para alimentar y validar el sistema.</i>		16
	4.1. Ejecución de pruebas unitarias y de integración del prototipo funcional.	Informes de Pruebas Unitarias y de Integración	4
	4.2. Adquisición masiva de datos multiespectrales en fincas cafeteras.	Datos Crudos Multiespectrales Recopilados	8
	4.3. Curación, etiquetado y validación del dataset con expertos agrónomos.	Dataset Multiespectral Etiquetado y Validado	4
Fase 5: Pruebas de Sistema y Validación en Campo	<i>Se verificará el sistema completo contra los requisitos definidos en la Fase 1, realizando validaciones en condiciones reales en fincas cafeteras para evaluar su precisión y robustez operativa.</i>		24
	5.1. Implementación del sistema prototipo en fincas cafeteras seleccionadas.	Sistema Prototipo Desplegado en Campo	4
	5.2. Ejecución de pruebas de campo y recopilación de retroalimentación de usuarios.	Informes de Pruebas de Campo y Encuestas de Usuarios	10
	5.3. Análisis de rendimiento y optimización del sistema en función de resultados de campo.	Informes de Optimización del Sistema	6

	5.4. Generación de informes de diagnóstico detallados para cada finca validada.	Informes de Diagnóstico por Finca	4
Fase 6: Despliegue, Optimización y Transferencia de Conocimiento	<i>Una vez validado, el sistema será optimizado con base en la retroalimentación de campo, desplegado para uso final, y se ejecutará el programa de capacitación y transferencia de conocimiento a los caficultores.</i>		24
	6.1. Optimización final del sistema y preparación para su despliegue.	Sistema Optimizado y Documentación de Despliegue	4
	6.2. Diseño y desarrollo del programa de capacitación y materiales didácticos.	Programa y Materiales de Capacitación	8
	6.3. Ejecución de talleres de capacitación para caficultores y técnicos.	Informes y Evidencias de Talleres de Capacitación	8
	6.4. Evaluación de impacto y cierre del programa de transferencia de conocimiento.	Informe Final de Transferencia de Conocimiento y Satisfacción	4

Matriz de Riesgos

7.2. Matriz de Riesgos

#	Riesgo Potencial	Probabilidad	Impacto	Estrategia de Mitigación
1	Baja precisión del modelo de IA en la detección de amenazas agrícolas. <i>Relacionado con: Fase 3, 4, 5</i>	Medium	High	Implementar un ciclo de desarrollo iterativo y ágil para los modelos de CNN, con pruebas tempranas y frecuentes. Establecer criterios de rendimiento claros desde la Fase 1 y realizar validaciones cruzadas continuas con datasets de referencia. Considerar el uso de técnicas de aumento de datos y arquitecturas pre-entrenadas para acelerar la convergencia y mejorar la robustez.
2	Dificultades o retrasos en la adquisición masiva de datos multiespectrales. <i>Relacionado con: Fase 4</i>	Medium	High	Establecer acuerdos formales con múltiples fincas cafeteras para asegurar el acceso. Desarrollar un plan de contingencia para el equipo de drones (e.g., drones de respaldo, personal capacitado adicional). Monitorear las previsiones meteorológicas y ajustar los cronogramas de vuelo proactivamente. Considerar la colaboración con instituciones que ya posean datasets complementarios.

3	Problemas de integración entre los diferentes módulos del sistema. <i>Relacionado con: Fase 2, 3, 4</i>	Medium	Medium	Adoptar un enfoque de desarrollo modular con interfaces bien definidas y estandarizadas desde la Fase 2. Realizar pruebas de integración continuas y tempranas (integración continua). Utilizar herramientas de gestión de versiones y plataformas de desarrollo colaborativo para asegurar la compatibilidad entre componentes. Asignar un líder técnico con experiencia en integración de sistemas complejos.
4	Baja aceptación o resistencia por parte de los caficultores. <i>Relacionado con: Fase 5, 6</i>	Medium	High	Involucrar a los caficultores clave desde las fases iniciales (Fase 1 y 5) a través de talleres y encuestas para entender sus necesidades y expectativas. Diseñar una interfaz de usuario intuitiva y fácil de usar. Desarrollar un programa de capacitación práctico y adaptado a su contexto, con seguimiento y soporte post-implementación. Resaltar los beneficios directos y tangibles del sistema.
5	Rendimiento deficiente del sistema prototípico en condiciones reales de campo. <i>Relacionado con: Fase 5</i>	High	High	

8. Resultados e Impactos Esperados

8.1. Resultados Esperados (Entregables)

- **Sistema Prototípico de Visión Artificial Inteligente:** Prototipo funcional de software y hardware para la detección y clasificación de enfermedades y deficiencias nutricionales en cultivos de café, con una precisión superior al 90% en entornos controlados. Corresponde al Objetivo Específico 1.
- **Documentación Técnica del Diseño del Sistema:** Informe detallado de la arquitectura de software, algoritmos de IA (CNNs) y especificaciones técnicas del sistema de visión artificial. Corresponde al Objetivo Específico 1.
- **Base de Datos Multiespectral de Cultivos de Café:** Un conjunto de datos robusto con un mínimo de 5,000 imágenes multiespectrales georreferenciadas de plantas de café, curado y etiquetado con la validación de expertos agrónomos. Corresponde al Objetivo Específico 2.
- **Protocolos de Vuelo y Adquisición de Datos:** Documentación estandarizada de las metodologías para la captura de imágenes multiespectrales con drones de bajo costo. Corresponde al Objetivo Específico 2.
- **Sistema de Detección de Amenazas Validado en Campo:** Versión optimizada del sistema de visión artificial, con una precisión de detección en campo del 85%, validado en al menos 3 fincas cafeteras representativas. Corresponde al Objetivo Específico 3.

-
- **Informes de Diagnóstico Detallados para Caficultores:** Reportes generados por el sistema con análisis de amenazas y recomendaciones, entregados a los caficultores de las fincas validadas. Corresponde al Objetivo Específico 3.
 - **Programa de Capacitación y Materiales Didácticos:** Currículo, presentaciones y manuales para la formación de caficultores y técnicos en el uso e interpretación del sistema. Corresponde al Objetivo Específico 4.
 - **Reportes de Capacitación y Retroalimentación de Usuarios:** Documentación de los talleres realizados, listas de asistentes, resultados de encuestas de satisfacción y análisis de la capacidad de los participantes para interpretar los diagnósticos. Corresponde al Objetivo Específico 4.

8.2. Impactos Esperados

● Impacto Técnico/Científico:

Este proyecto contribuirá significativamente al avance del conocimiento en la aplicación de la inteligencia artificial y la visión artificial en la agricultura de precisión, particularmente en cultivos de café de pequeña escala. Se desarrollará una metodología innovadora para la detección temprana y precisa de amenazas agrícolas utilizando drones de bajo costo y redes neuronales convolucionales, adaptada a las condiciones agroecológicas específicas del Quindío. La creación de un dataset multiespectral especializado para café en la región es un aporte científico valioso que servirá como base para futuras investigaciones y desarrollos tecnológicos en el sector.

● Impacto Económico:

El proyecto tendrá un impacto económico directo en la productividad y rentabilidad de las pequeñas fincas cafeteras. Al permitir la detección temprana de enfermedades y deficiencias nutricionales, se facilitará una intervención oportuna y localizada, reduciendo las pérdidas de cosecha hasta en un 25% y optimizando el uso de insumos agrícolas (fertilizantes y pesticidas). Esto se traducirá en una disminución de costos de producción y un aumento en la calidad y cantidad del café producido, mejorando la competitividad y la resiliencia económica de los caficultores del Quindío. Además, sentará las bases para la creación de nuevos servicios tecnológicos locales en torno a la agricultura de precisión.

● Impacto Social/Ambiental:

A nivel social, el proyecto empoderará a los pequeños caficultores al proporcionarles acceso a tecnología avanzada y conocimiento especializado, cerrando la brecha digital y tecnológica. El programa de capacitación mejorará las habilidades técnicas de la comunidad, fomentando la toma de decisiones informadas y promoviendo una cultura de innovación. Esto contribuirá a la mejora de la calidad de vida y el bienestar de las familias caficultoras. Desde el punto de vista ambiental, la detección precisa y temprana de amenazas permitirá una reducción sustancial en el uso indiscriminado de agroquímicos, minimizando la contaminación del suelo y el agua, y promoviendo prácticas agrícolas más sostenibles y respetuosas con el medio ambiente. Esto es crucial para la conservación de la biodiversidad y los ecosistemas cafeteros del Quindío.

9. Referencias Bibliográficas

Daraojimba, D. O., Adewusi, A. O., Asuzu, O. F., Olorunsogo, T., Iwuanyanwu, C., & Adaga, E. (2024). AI in precision agriculture: A review of technologies for sustainable farming practices. [*No Journal/Publisher Information Available in Snippet*].

De Silva, M., & Brown, D. (2023). Multispectral Plant Disease Detection with Vision Transformer–Convolutional Neural Network Hybrid Approaches. *Sensors*, 23(15), 6750. <https://doi.org/10.3390/s23156750>

Gani, R., Isty, M. N., Rashid, M. R. A., Ahmed, J., Islam, T., Hasan, M., Islam, R. U., Ripon, S., & Reza, A. W. (2025). Attention guided convolutional neural network with explainable AI for papaya leaf disease detection in edge and drone agricultural systems. *Computers and Electronics in Agriculture*, 220, 108866. <https://doi.org/10.1016/j.compag.2025.108866>

Hamila, O., Henry, C. J., Molina, O. I., Bidinosti, C., & Henriquez, M. (2023). Fusarium head blight detection, spikelet estimation, and severity assessment in wheat using 3D convolutional neural networks. *Scientific Reports*, 13(1), 10834. <https://doi.org/10.1038/s41598-023-37965-w>

Husnain, A., Ahmad, A., & Saeed, A. (2024). Enhancing agricultural health with AI: Drone-based machine learning for mango tree disease detection. *Computers and Electronics in Agriculture*, 219, 108789. <https://doi.org/10.1016/j.compag.2024.108789>

rpas-drones.com. (n.d.). *Cómo el café se apoya en la cartografía con drones*. Recuperado de <https://rpas-drones.com/como-el-cafe-se-apoya-en-la-cartografia-con-drones/>

Unitxlabs. (n.d.). *Por qué los sistemas de visión artificial para la agricultura son un cambio de juego*. Recuperado de <https://es.unitxlabs.com/agriculture-machine-vision-systems-game-changers/>