



Eco-Vigilancia Austral: Integración de LLMs Multimodales y Drones Autónomos para la Detección de Deforestación y Planificación Agrícola Sostenible en Sudamérica

1. Resumen Ejecutivo

1. Resumen Ejecutivo

La deforestación en Sudamérica, especialmente en la Cuenca Amazónica y el Gran Chaco, representa una amenaza ambiental crítica, con la detección temprana y precisa siendo un desafío persistente. El proyecto Eco-Vigilancia Austral surge como una solución innovadora, proponiendo el desarrollo de un sistema híbrido que integra drones autónomos con sensores avanzados y Modelos de Lenguaje Grandes Multimodales (MLLMs). Nuestra visión es transformar la mera detección de la deforestación en planes de acción proactivos y estratégicos para la conservación y el desarrollo sostenible.

Para lograr esta visión, el proyecto se estructura en objetivos clave: desarrollar un módulo de detección de deforestación de alta precisión ($>95\%$ F1-score) mediante MLLMs y datos de drones, integrar esta información con bases de datos socioeconómicas y agronómicas para generar estrategias agrícolas sostenibles (con al menos 100 informes contextualizados por trimestre), y desplegar y validar operativamente el sistema completo en entornos reales con usuarios finales. Adoptaremos el Modelo en V de Ingeniería de Sistemas, un framework robusto ideal para la integración de hardware y software complejos, garantizando una validación rigurosa en cada etapa.

Los resultados esperados incluyen un Módulo de Detección de Deforestación basado en MLLMs, un Motor de Razonamiento para Estrategias Agrícolas Sostenibles, y el Sistema Eco-Vigilancia Austral operativo y validado en campo. Estos entregables generarán un impacto transformador: un avance significativo en la aplicación de MLLMs para la teledetección ambiental con una precisión sin precedentes (impacto técnico/científico), la optimización de recursos y la mejora de la productividad agrícola sostenible (impacto económico), y una reducción sustancial de la deforestación, empoderando a las comunidades y fomentando la gobernanza territorial (impacto social y ambiental).

Eco-Vigilancia Austral no es solo un avance tecnológico; es una herramienta estratégica vital que armonizará la producción económica con la protección ambiental, sentando un precedente para la gestión sostenible de recursos naturales a nivel regional y global.

2. Generalidades del Proyecto

- **Descripción:** Este proyecto propone el desarrollo de un sistema híbrido de monitoreo ambiental enfocado en zonas rurales críticas de Sudamérica (con énfasis en la Cuenca Amazónica y el Gran Chaco). La solución integra una red logística de vehículos aéreos no tripulados (drones) equipados con sensores ópticos y multiespectrales para la recolección de datos in situ en áreas de difícil acceso. La innovación principal radica en el procesamiento de esta data mediante Modelos de Lenguaje Grandes Multimodales (MLLMs). Estos modelos no solo identificarán patrones visuales de tala ilegal o expansión no planificada, sino que correlacionarán estos hallazgos con datos socioeconómicos y agronómicos para generar, mediante razonamiento artificial, informes de estrategia agrícola. El objetivo final es proporcionar a las comunidades locales y organismos gubernamentales planes de acción para mejorar la productividad agrícola sin expandir la frontera de deforestación.

- **Palabras Clave:** Detección de Deforestación, LLMs Multimodales, Drones (VANT), Agricultura de Precisión, Teledetección con IA

3. Planteamiento del Problema y Justificación

La deforestación representa una de las amenazas ambientales más apremiantes a nivel global, con impactos devastadores en la biodiversidad, el clima y los medios de vida de las comunidades, particularmente en regiones de alta vulnerabilidad ecológica como la Cuenca Amazónica y el Gran Chaco en Sudamérica. A pesar de los esfuerzos internacionales y nacionales, la detección temprana y precisa de la tala ilegal y la expansión agrícola no planificada sigue siendo un desafío crucial. La incapacidad de monitorear eficazmente estos cambios a gran escala resulta en una pérdida irrecuperable de recursos naturales y una exacerbación de las crisis climáticas y sociales.

Como indica el "Marco Teórico y Estado del Arte", la teledetección y la Inteligencia Artificial (IA) han emergido como herramientas fundamentales para el monitoreo ambiental. Avances significativos en el uso de vehículos aéreos no tripulados (VANT o drones) con sensores RGB, multiespectrales e hiperespectrales (Hernández et al., 2024; Buitrago Bolívar et al., 2024) permiten la recolección de datos de alta resolución, superando las limitaciones de las imágenes satelitales. Paralelamente, la emergencia de los Modelos de Lenguaje Grandes Multimodales (MLLMs) ha revolucionado la interpretación de datos complejos, procesando información visual y textual para tareas de clasificación y detección (Weng et al., 2025; Liu et al., 2025). Sin embargo, existe una brecha crítica: mientras los MLLMs han demostrado su capacidad en la interpretación de imágenes y texto, su aplicación integral para la detección de deforestación utilizando datos multiespectrales/hiperespectrales de alta resolución recolectados por drones, y la posterior correlación con datos socioeconómicos y agronómicos para generar planes de acción estratégicos, es un área relativamente inexplorada. La mayoría de los estudios se centran en la detección o en la agricultura por separado, o utilizan imágenes satelitales de menor resolución, y los sistemas actuales carecen de la capacidad de transformar los datos de detección en planes de acción coherentes y contextualizados que equilibren la productividad agrícola con la conservación ambiental.

El proyecto Eco-Vigilancia Austral emerge como la respuesta lógica y necesaria para abordar estas brechas fundamentales. Al proponer el desarrollo de un sistema híbrido que integra una red logística de drones equipados con sensores ópticos y multiespectrales para la recolección de datos in situ de alta resolución, y Modelos de Lenguaje Grandes Multimodales para el procesamiento de esta información, el proyecto supera las limitaciones actuales. La innovación central radica en la capacidad de estos MLLMs para no solo identificar patrones visuales de tala ilegal o expansión no planificada, sino para correlacionar estos hallazgos con datos socioeconómicos y agronómicos, generando, mediante razonamiento artificial, informes de estrategia agrícola. Este enfoque holístico transformará la mera detección en una solución proactiva y orientada a la acción.

La implementación de Eco-Vigilancia Austral es, por tanto, oportuna y crítica. Este proyecto no solo representa un avance tecnológico significativo en la intersección de la IA y la teledetección, sino que ofrece una herramienta estratégica vital para la sostenibilidad en Sudamérica. Su impacto potencial es transformador: proporcionará a las comunidades locales y a los organismos gubernamentales planes de acción concretos y basados en evidencia para mejorar la productividad agrícola, al tiempo que detiene la expansión de la frontera de deforestación. De esta manera, Eco-Vigilancia Austral no solo contribuirá a la conservación de ecosistemas cruciales, sino que también fomentará un modelo de

desarrollo rural que armoniza la producción económica con la protección ambiental, sentando un precedente para la gestión sostenible de recursos naturales a nivel regional y global.

4. Marco Teórico y Estado del Arte

4. Marco Teórico y Estado del Arte

4.1. Introducción al Dominio

La deforestación representa una de las amenazas ambientales más apremiantes a nivel global, con impactos devastadores en la biodiversidad, el clima y los medios de vida de las comunidades. Particularmente en regiones como la Cuenca Amazónica y el Gran Chaco en Sudamérica, la detección temprana y precisa de la tala ilegal y la expansión agrícola no planificada es biodiversidad, el clima y los medios de vida de las comunidades. Particularmente en regiones como la Cuenca Amazónica y el Gran Chaco en Sudamérica, la detección temprana y precisa de la tala ilegal y la expansión agrícola no planificada es crucial para la conservación y el desarrollo sostenible. La teledetección, combinada con el avance exponencial de la Inteligencia Artificial (IA), ha emergido como una herramienta fundamental para monitorear estos cambios a gran escala. Este proyecto se enmarca en la intersección de estas disciplinas, proponiendo un sistema innovador que integra vehículos aéreos no tripulados (VANT o drones) con sensores avanzados y Modelos de Lenguaje Grandes Multimodales (MLLMs) para una vigilancia ambiental proactiva y una planificación agrícola optimizada.

La agricultura de precisión, un paradigma que busca optimizar el rendimiento de los cultivos y minimizar el impacto ambiental mediante el uso de datos y tecnologías avanzadas, se beneficia enormemente de la teledetección y la IA. Al combinar la capacidad de los drones para recolectar datos de alta resolución in situ con la sofisticación de los MLLMs para interpretar patrones complejos y generar razonamiento contextual, se abre una nueva frontera en la gestión de recursos naturales. Este enfoque no solo permite la identificación de áreas degradadas, sino que también facilita la creación de estrategias agrícolas que promuevan la productividad sin contribuir a la deforestación, abordando así los desafíos socioeconómicos y ambientales de manera integral.

4.2. Revisión de la Literatura (Literature Review)

La literatura reciente destaca la creciente sofisticación en la detección de la deforestación y la gestión agrícola sostenible a través de la IA y la teledetección. **Hernández et al. (2024)**, en su revisión sobre el monitoreo minero en el Cono Sur, subrayan el potencial de los sensores hiperespectrales, UAV y radar, integrados con aprendizaje profundo, para detectar disturbios ambientales, incluyendo la deforestación. Este trabajo enfatiza la necesidad de metodologías colaborativas y herramientas computacionales avanzadas para la toma de decisiones, lo cual resalta la relevancia de la integración tecnológica propuesta en nuestro proyecto.

En el ámbito de la agricultura de precisión, **Buitrago Bolívar et al. (2024)** realizaron una revisión exhaustiva sobre el monitoreo de cultivos y suelos con UAV e IA, identificando una tendencia hacia el uso de drones con sensores RGB, multiespectrales, hiperespectrales y LiDAR. Su estudio concluye que las técnicas de aprendizaje automático y profundo, especialmente la fusión multimodal de datos, son prometedoras para estimar parámetros clave del cultivo y superar limitaciones de métodos clásicos. Asimismo, **Vera Medranda y Zambrano Solórzano (2025)** y **Sánchez Palacios et al. (2024)**, discuten el impacto y los beneficios de los drones en la agricultura, destacando su rol en la

optimización de recursos y la sostenibilidad, y su aplicación en regiones como Ecuador.

La emergencia de los Modelos de Lenguaje Grandes Multimodales (MLLMs) ha revolucionado la interpretación de datos complejos. **Weng et al. (2025)** ofrecen una visión general de la modelización visión-lenguaje en teledetección, resaltando el progreso logrado mediante el pre-entrenamiento en pares masivos de imagen-texto y el ajuste fino en datos específicos de la tarea. Este enfoque permite a los modelos absorber conocimiento general y demostrar un rendimiento robusto. Complementariamente, **Liu et al. (2025)** exploran los MLLMs espacio-temporales para la teledetección, indicando que la fusión de modalidades visuales y lingüísticas permite una interpretación más profunda de los procesos dinámicos de la Tierra, superando las limitaciones de los métodos tradicionales de detección de cambios. La necesidad de modelos más compactos para hardware de borde en aplicaciones de teledetección es abordada por **Koksal y Alatan (2025)** con TinyRS-R1, un modelo de 2B parámetros optimizado para estas tareas.

La aplicación directa de MLLMs en agricultura de precisión ha sido explorada por **Bie et al. (2025)**, quienes proponen adaptar MLLMs para la segmentación de cultivos en imágenes de teledetección de UAV, reformulando la tarea como un formato conversacional. Sus hallazgos demuestran que los VLMs adaptados pueden realizar eficazmente tareas de segmentación, ofreciendo ventajas en escenarios de aprendizaje con pocas muestras. **Tan et al. (2023)** también exploran las promesas y desafíos de los modelos fundacionales multimodales (como GPT-4V) para aplicaciones geográficas, ambientales y agrícolas, evaluando su rendimiento en tareas como clasificación de imágenes de teledetección y análisis del comportamiento de cultivos.

Finalmente, la integración de estas tecnologías para la planificación agrícola sostenible se ve reflejada en trabajos como el de **Zuzuárregui et al. (2025)**, quienes proponen la planificación de misiones heterogéneas basada en LLMs para la agricultura de precisión, simplificando la complejidad para usuarios no técnicos. La importancia de la planificación del uso del suelo para la sostenibilidad también es destacada por **Tariq y Mumtaz (2023)**, que utilizan modelos de cadena de Markov y autómatas celulares para predecir cambios en la cobertura del suelo y advertir sobre la reducción de áreas forestales si las tendencias actuales continúan.

4.3. Tecnologías y Enfoques Actuales (State of the Art)

El estado del arte en la vigilancia ambiental y la agricultura sostenible se caracteriza por la convergencia de varias tecnologías avanzadas. En la **detección de deforestación**, los sistemas actuales se basan predominantemente en el análisis de imágenes satelitales (ópticas, radar) utilizando algoritmos de aprendizaje profundo, como Redes Neuronales Convolucionales (CNNs) y arquitecturas de tipo Transformer. Iniciativas como "Guacamaya" en Colombia (Uniandes, sin fecha), PrevisIA en Brasil (Forbes Colombia, 2023) y Forest Foresight en Bolivia (WWF, 2023) son ejemplos exitosos de la aplicación de IA para procesar grandes volúmenes de imágenes satelitales y predecir áreas de riesgo de deforestación, permitiendo intervenciones gubernamentales oportunas.

Los **drones autónomos** son fundamentales para la recolección de datos de alta resolución, superando las limitaciones de las imágenes satelitales en términos de detalle y flexibilidad. Equipados con una variedad de sensores (RGB, multiespectrales, hiperespectrales, térmicos y LiDAR), los drones permiten el monitoreo detallado de cultivos, la detección temprana de enfermedades y plagas, la evaluación de la salud del suelo y la identificación de cambios sutiles en la cobertura forestal (Buitrago Bolívar et al., 2024; Vera Medranda & Zambrano Solórzano, 2025). Los avances en la autonomía de

vuelo y la planificación de rutas eficientes (Zhu & Ghandeharizadeh, 2024) mejoran la escalabilidad de estas operaciones.

La **integración de Modelos de Lenguaje Grandes Multimodales (MLLMs)** representa una de las fronteras más prometedoras. Estos modelos, como Qwen2-VL y LLaVA, son capaces de procesar e interpretar información de múltiples modalidades, incluyendo imágenes y texto. En teledetección, se utilizan para tareas de clasificación, detección de objetos, respuesta a preguntas visuales (VQA) y, más recientemente, para la segmentación de imágenes agrícolas mediante la conversión de etiquetas a formatos conversacionales (Bie et al., 2025; Tan et al., 2023). La capacidad de los MLLMs para generar descripciones en lenguaje natural y realizar razonamiento contextual a partir de datos visuales es clave para transformar los datos brutos en información actionable.

En **agricultura de precisión**, la IA se aplica para la optimización del riego, la fertilización variable, la predicción de rendimientos y el manejo integrado de plagas. Los MLLMs están empezando a ser explorados para la planificación de misiones y la generación de recomendaciones personalizadas, actuando como "agentes" que traducen descripciones de tareas en lenguaje natural en programas ejecutables por drones o maquinaria agrícola (Zuzuárregui et al., 2025; TypeFly, sin fecha).

4.4. Brechas de Conocimiento y Oportunidades (Knowledge Gaps & Opportunities)

A pesar de los avances significativos, existen brechas críticas que el proyecto Eco-Vigilancia Austral busca abordar. Primero, si bien los MLLMs han demostrado su capacidad en la interpretación de imágenes y texto, su aplicación integral para la **detección de deforestación utilizando datos multiespectrales/hiperespectrales de alta resolución recolectados por drones, y la posterior correlación con datos socioeconómicos y agronómicos para generar planes de acción estratégicos**, es un área relativamente inexplorada. La mayoría de los estudios se centran en la detección o en la agricultura por separado, o utilizan imágenes satelitales de menor resolución. La integración de la riqueza espectral de los sensores de drones con la capacidad de razonamiento multimodal de los LLMs para un análisis holístico es una oportunidad clave.

Segundo, la implementación efectiva de MLLMs en entornos de campo, a menudo con recursos computacionales limitados (como en drones o estaciones de procesamiento local en áreas remotas), requiere **modelos más compactos y eficientes**. Aunque existen esfuerzos como TinyRS-R1 (Koksal & Alatan, 2025), la optimización de MLLMs para tareas duales de detección de deforestación y planificación agrícola sostenible en hardware de borde sigue siendo un desafío.

Tercero, la capacidad de los MLLMs para ir más allá de la mera identificación y generar **informes de estrategia agrícola mediante razonamiento artificial** que sean directamente aplicables por comunidades locales y organismos gubernamentales representa una brecha significativa. Los sistemas actuales a menudo proporcionan datos de detección, pero la conversión de estos datos en planes de acción coherentes y contextualizados, que equilibren la productividad agrícola con la conservación ambiental, es un área donde los MLLMs pueden aportar un valor diferencial. Esta capacidad de "razonamiento" y generación de recomendaciones es el núcleo de la innovación propuesta, cerrando la brecha entre la observación tecnológica y la acción estratégica en el terreno.

5. Objetivos

Desarrollar e implementar un sistema híbrido innovador que integre drones autónomos con sensores avanzados y Modelos de Lenguaje Grandes Multimodales (MLLMs) para la detección temprana y precisa de la deforestación, y la generación de estrategias agrícolas sostenibles en regiones vulnerables de Sudamérica, transformando la detección en planes de acción proactivos para la conservación y el desarrollo.

1. Objetivo: Desarrollar un Módulo de Detección de Deforestación de Alta Precisión.

- **Específico (S):** Diseñar y desarrollar un módulo de procesamiento de imágenes basado en MLLMs capaz de analizar datos multiespectrales e hiperespectrales recolectados por drones para identificar y clasificar áreas de deforestación y cambios en el uso del suelo con una granularidad espacial sin precedentes en al menos tres zonas piloto de la Cuenca Amazónica y el Gran Chaco.
- **Medible (M):** Lograr una precisión de detección de deforestación superior al 95% (F1-score) y una reducción del 80% en falsos positivos/negativos en comparación con métodos satelitales convencionales, verificable mediante validación en campo en las zonas piloto seleccionadas.
- **Alcanzable (A):** Este objetivo es tecnológicamente alcanzable dada la convergencia de los avances en MLLMs y la teledetección de alta resolución con drones. El equipo cuenta con la experiencia necesaria en IA y procesamiento de imágenes para superar los desafíos técnicos.
- **Relevante (R):** Este módulo es la base del proyecto, ya que aborda directamente la necesidad de una detección temprana y precisa, una deficiencia clave en la lucha contra la deforestación, y es fundamental para la generación posterior de estrategias, contribuyendo directamente al objetivo general.
- **Plazo (T):** Completar el desarrollo, entrenamiento y la validación inicial del módulo de detección dentro de los primeros 12 meses del proyecto.

2. Objetivo: Integrar Datos y Generar Estrategias Agrícolas Sostenibles mediante MLLMs.

- **Específico (S):** Implementar un sistema robusto de integración de datos que combine la información geoespacial de deforestación y uso del suelo (obtenida por drones y MLLMs) con bases de datos socioeconómicas, climáticas y agronómicas existentes. Posteriormente, desarrollar y entrenar los MLLMs para que, mediante razonamiento artificial, generen informes de estrategia agrícola sostenible personalizados y planes de acción para comunidades y autoridades locales.
- **Medible (M):** Desarrollar un motor de razonamiento basado en MLLMs que produzca al menos 100 informes de estrategia agrícola contextualizados por trimestre para las zonas piloto, los cuales deben ser evaluados por un panel de expertos con una tasa de aprobación del 85% en términos de coherencia, relevancia y viabilidad para la sostenibilidad local.
- **Alcanzable (A):** La capacidad de los MLLMs para procesar y correlacionar datos complejos multimodales (visuales, textuales, numéricos) para generar narrativas y planes coherentes ha sido demostrada. El enfoque estará en la contextualización y validación de los resultados con expertos sectoriales.
- **Relevante (R):** Este objetivo es crucial para transformar la "mera detección en una solución proactiva y orientada a la acción", cerrando la brecha entre el monitoreo y la implementación de soluciones prácticas para la sostenibilidad ambiental y agrícola, vital para el objetivo general del proyecto.

- **Plazo (T):** Establecer la funcionalidad completa de integración de datos y generación de estrategias basadas en MLLMs dentro de los 18 meses del proyecto.
- 3. Objetivo:** Desplegar y Validar el Sistema Eco-Vigilancia Austral en Entornos Reales.
- **Específico (S):** Desplegar y probar la operatividad del sistema Eco-Vigilancia Austral completo (incluyendo la red logística de drones, el módulo MLLM de detección y el generador de estrategias) en al menos tres comunidades piloto en Sudamérica, involucrando activamente a usuarios finales (comunidades locales, organismos gubernamentales y agrícolas) para validar su usabilidad, eficacia y el impacto real en la toma de decisiones y la gestión sostenible del territorio.
 - **Medible (M):** Recopilar feedback de al menos 50 usuarios finales, logrando una puntuación promedio de satisfacción de 4.0/5.0 en la usabilidad y utilidad del sistema. Además, documentar una mejora del 20% en la velocidad de respuesta a incidentes de deforestación o en la implementación de prácticas agrícolas sostenibles en las zonas piloto, medida a través de indicadores de gestión local.
 - **Alcanzable (A):** La fase de despliegue y validación es una etapa estándar en proyectos de I+D. Se establecerán acuerdos de colaboración con socios locales y se contará con un equipo de campo para facilitar la implementación y el soporte técnico, garantizando la viabilidad del despliegue.
 - **Relevante (R):** Este objetivo asegura que el sistema no solo sea una proyección tecnológica, sino una herramienta práctica, útil y adoptable por los usuarios finales. Su éxito es directamente proporcional al impacto transformador del proyecto en la sostenibilidad regional y el cumplimiento del objetivo general de proporcionar una herramienta estratégica vital.
 - **Plazo (T):** Completar la fase de despliegue y validación en campo, incluyendo la recopilación y análisis de feedback, dentro de los 24 meses del proyecto.

6. Metodología Propuesta

6. Metodología Propuesta

Framework Seleccionado: Modelo en V de Ingeniería de Sistemas

El Modelo en V ha sido seleccionado como el framework metodológico principal debido a la naturaleza híbrida y la complejidad del proyecto "Eco-Vigilancia Austral". Este enfoque es ideal para proyectos que combinan el desarrollo de hardware (drones y sensores avanzados) con software complejo (Modelos de Lenguaje Grandes Multimodales - MLLMs), donde la integración y la validación rigurosa en cada etapa son críticas. Su estructura lineal y el énfasis en la verificación y validación en cada fase de desarrollo aseguran que los requisitos definidos se cumplan con alta precisión y que el sistema integrado funcione de manera fiable, lo cual es fundamental para alcanzar los objetivos de detección de deforestación con una precisión superior al 95% y la generación de estrategias sostenibles validadas en campo.

Fases Principales de la Metodología:

- **Fase 1: Análisis de Requisitos y Concepto Operacional** - Esta fase implica la definición detallada de los requisitos funcionales y no funcionales del sistema, incluyendo las especificaciones para la detección de deforestación y la generación de estrategias agrícolas, así como la definición del concepto de operación del sistema en entornos reales.

- **Fase 2: Diseño de la Arquitectura del Sistema** - Se diseñará la arquitectura global del sistema Eco-Vigilancia Austral, delineando la integración de los drones autónomos, los sensores multiespectrales, los módulos MLLM, la plataforma de procesamiento de datos y la interfaz de usuario.
- **Fase 3: Desarrollo y Diseño Detallado de Módulos** - Consiste en la implementación de los módulos de software basados en MLLMs para la detección de deforestación y la generación de estrategias, así como la configuración y adaptación de los componentes de hardware (drones y sensores) según las especificaciones de diseño.
- **Fase 4: Pruebas de Componentes e Integración** - Se realizarán pruebas unitarias para verificar la funcionalidad de cada módulo de software y hardware de forma individual, seguidas de pruebas de integración para asegurar la correcta comunicación y el flujo de datos entre todos los componentes del sistema híbrido.
- **Fase 5: Verificación y Validación del Sistema** - En esta fase, el sistema completo Eco-Vigilancia Austral será sometido a pruebas exhaustivas en un entorno controlado para verificar que cumple con todos los requisitos de rendimiento y precisión definidos en la Fase 1.
- **Fase 6: Despliegue y Validación en Entornos Reales** - El sistema será desplegado en las zonas piloto de Sudamérica para su operación y validación en campo, involucrando a usuarios finales para evaluar su usabilidad, eficacia y el impacto real en la toma de decisiones y la gestión territorial sostenible.

7. Plan de Ejecución y Gestión

7.1. Cronograma de Actividades

Fase	Actividad / Hito Clave	Entregable Principal	Duración Estimada (Semanas)
Fase 1: Análisis de Requisitos y Concepto Operacional	<i>Establecimiento de las bases del proyecto, definiendo requisitos técnicos, operativos y funcionales para los módulos de detección y estrategias, y el concepto de operación general del sistema.</i>	6	
1.1. Recopilación y análisis de requisitos detallados para el módulo MLLM de detección de deforestación.	Documento de Requisitos del Módulo de Detección	4	
1.2. Definición de requisitos funcionales y no funcionales para la integración de datos y el MLLM de generación de estrategias agrícolas.	Especificaciones de Requisitos para Módulo de Estrategias	4	

Fase	Actividad / Hito Clave	Entregable Principal	Duración Estimada (Semanas)
1.3. Elaboración del Concepto Operacional (ConOps) del sistema Eco-Vigilancia Austral y casos de uso.	Concepto de Operaciones (ConOps)	2	
Fase 2: Diseño de la Arquitectura del Sistema	<i>Desarrollo del diseño arquitectónico global del sistema, incluyendo la integración de hardware (drones/sensores) y software (MLLMs, plataforma de datos, interfaz de usuario).</i>	8	
2.1. Diseño de la arquitectura del módulo MLLM de detección y del subsistema de procesamiento de imágenes.	Documento de Diseño de Arquitectura (Detección)	5	
2.2. Diseño de la arquitectura de integración de datos y del motor MLLM para la generación de estrategias.	Documento de Diseño de Arquitectura (Estrategias)	5	
2.3. Diseño de la arquitectura de hardware (drones, sensores) y de la interfaz de usuario del sistema.	Esquema de Arquitectura de Hardware y UI	4	
Fase 3: Desarrollo y Diseño Detallado de Módulos	<i>Implementación de los componentes de software basados en MLLMs y configuración del hardware, centrándose en el desarrollo funcional de los módulos clave del proyecto.</i>	18	
3.1. Desarrollo y entrenamiento inicial del módulo MLLM de detección de deforestación.	Módulo MLLM de Detección (Versión Alpha)	12	
3.2. Implementación del sistema de integración de datos y desarrollo del motor MLLM de generación de estrategias.	Módulo MLLM de Estrategias (Versión Alpha)	14	
3.3. Configuración, calibración y adaptación de drones autónomos y sensores multiespectrales.	Hardware de Drones y Sensores Configurado	8	

Fase	Actividad / Hito Clave	Entregable Principal	Duración Estimada (Semanas)
3.4. Desarrollo de la plataforma de visualización geoespacial y la interfaz de usuario.	Plataforma de Usuario (Versión Alpha)	10	
Fase 4: Pruebas de Componentes e Integración	<i>Verificación de la funcionalidad de cada módulo de forma individual y de su correcta interacción, asegurando la comunicación y el flujo de datos entre todos los componentes del sistema híbrido.</i>	10	
4.1. Pruebas unitarias y de rendimiento del módulo MLLM de detección de deforestación.	Informe de Pruebas Unitarias (Detección)	4	
4.2. Pruebas de integración del módulo MLLM de detección con el hardware de drones y la plataforma de procesamiento.	Informe de Pruebas de Integración (Detección)	4	
4.3. Pruebas unitarias y de integración del módulo MLLM de estrategias y el sistema de integración de datos.	Informe de Pruebas Unitarias y Integración (Estrategias)	6	
4.4. Pruebas de integración del sistema híbrido completo (drones, MLLMs, UI).	Informe de Pruebas de Integración del Sistema Híbrido	4	
Fase 5: Verificación y Validación del Sistema	<i>Pruebas exhaustivas del sistema completo en un entorno controlado para verificar que cumple con los requisitos de rendimiento y precisión definidos, con un enfoque en la validación de los objetivos clave.</i>	12	
5.1. Verificación de precisión del módulo de detección de deforestación ($F1\text{-score} > 95\%$) en entorno simulado.	Informe de Verificación de Detección	6	
5.2. Validación de la coherencia, relevancia y viabilidad de las estrategias agrícolas con panel de expertos.	Informe de Validación de Estrategias (v1.0)	6	

Fase	Actividad / Hito Clave	Entregable Principal	Duración Estimada (Semanas)
5.3. Pruebas de rendimiento, escalabilidad y estabilidad del sistema Eco-Vigilancia Austral integrado.	Informe de Pruebas de Rendimiento del Sistema	6	
Fase 6: Despliegue y Validación en Entornos Reales	<i>Implementación del sistema en zonas piloto de Sudamérica para su operación y validación en campo, recopilando feedback de usuarios finales y evaluando su impacto real.</i>	50	
6.1. Planificación logística, acuerdos con socios locales y despliegue del sistema en tres zonas piloto.	Plan de Despliegue y Acuerdos de Colaboración	6	
6.2. Operación y monitoreo continuo del sistema en campo, recolección de datos y generación de informes de monitoreo y estrategias.	Datos de Campo y Reportes de Monitoreo Continuo	24	
6.3. Recopilación y análisis iterativo de feedback de usuarios finales sobre usabilidad y utilidad del sistema.	Informes de Feedback de Usuarios y Satisfacción (Iterativos)	12	
6.4. Evaluación del impacto en la toma de decisiones, implementación de mejoras y elaboración del informe final de validación en campo.	Informe Final de Validación, Mejoras Implementadas	8	

7.2. Matriz de Riesgos

#	Riesgo Potencial	Probabilidad	Impacto	Estrategia de Mitigación
1	MLLM de detección no alcanza la precisión requerida (F1-score > 95%) <i>Relacionado con: Fase 3.1 (Desarrollo y entrenamiento inicial del módulo MLLM de detección) y Fase 5.1 (Verificación de precisión del módulo de detección).</i>	Medium	High	Implementar un ciclo de desarrollo iterativo y pruebas tempranas del MLLM. Establecer métricas de rendimiento intermedias y explorar arquitecturas de modelos alternativas o técnicas de aumento de datos si los resultados iniciales son insuficientes. Contar con un plan de contingencia para el ajuste fino o reentrenamiento intensivo.
2	Problemas de integración entre drones, sensores y los módulos MLLM <i>Relacionado con: Fase 2 (Diseño de la Arquitectura), Fase 3.3 (Configuración, calibración y adaptación de drones) y Fase 4 (Pruebas de Componentes e Integración).</i>	Medium	High	Realizar pruebas de integración incrementales desde las fases tempranas del diseño. Utilizar interfaces bien definidas y estándares de comunicación abiertos. Designar un equipo de integración dedicado y realizar simulaciones de interfaz antes de la integración física de los componentes.

#	Riesgo Potencial	Probabilidad	Impacto	Estrategia de Mitigación
3	Retrasos en la obtención de permisos o acuerdos con socios locales <i>Relacionado con: Fase 6.1 (Planificación logística, acuerdos con socios locales y despliegue del sistema).</i>	High	High	Iniciar las negociaciones y procesos de obtención de permisos con antelación, idealmente desde la Fase 2 o 3. Establecer comunicación constante y transparente con las autoridades y socios locales. Desarrollar planes de contingencia para zonas piloto alternativas en caso de impedimentos.
4	Insuficiencia o baja calidad de datos para el entrenamiento de los MLLMs <i>Relacionado con: Fase 1.1, 1.2 (Recopilación y análisis de requisitos) y Fase 3.1, 3.2 (Desarrollo y entrenamiento inicial de los MLLMs).</i>	Medium	High	Realizar un estudio exhaustivo de disponibilidad de datos y desarrollar un plan de adquisición de datos robusto al inicio del proyecto. Implementar técnicas de aumento de datos, transferencia de aprendizaje y buscar colaboraciones con instituciones de investigación locales para acceder a datasets existentes.
5	Baja aceptación o utilidad percibida por los usuarios finales en las zonas piloto <i>Relacionado con: Fase 6.3 (Recopilación y análisis iterativo de feedback de usuarios finales) y 6.4 (Evaluación del impacto).</i>	Medium	High	Involucrar a los usuarios finales y expertos agrícolas locales en el diseño y validación del sistema desde las fases tempranas del proyecto. Realizar prototipos y pruebas de usabilidad tempranas, e incorporar sus comentarios de forma iterativa en el desarrollo y las mejoras del sistema.

#	Riesgo Potencial	Probabilidad	Impacto	Estrategia de Mitigación
6	Disponibilidad limitada de expertos en MLLMs multimodales o operación de drones autónomos <i>Relacionado con: Todas las fases de desarrollo y despliegue (Fases 1-6).</i>	Medium	Medium	Identificar y asegurar la contratación de personal clave con la experiencia requerida desde las fases iniciales. Establecer un plan de capacitación interna para el equipo existente y mantener una red de consultores externos para apoyo puntual en áreas especializadas.

8. Resultados e Impactos Esperados

8. Resultados e Impactos Esperados

8.1. Resultados Esperados (Entregables)

- **Módulo de Detección de Deforestación de Alta Precisión basado en MLLMs:** Un software o algoritmo avanzado, entrenado con Modelos de Lenguaje Grandes Multimodales (MLLMs), capaz de analizar datos multiespectrales e hiperespectrales de drones para identificar y clasificar la deforestación y los cambios de uso del suelo con una precisión superior al 95% (F1-score) y una reducción del 80% en falsos positivos/negativos. (Corresponde al Objetivo Específico 1)
- **Plataforma de Integración de Datos Geoespaciales y Socioeconómicos:** Un sistema robusto para la agregación, procesamiento y gestión de datos geoespaciales de deforestación y uso del suelo, junto con información socioeconómica, climática y agronómica relevante, sirviendo de base para el razonamiento de los MLLMs. (Corresponde al Objetivo Específico 2)
- **Motor de Razonamiento y Generación de Estrategias Agrícolas Sostenibles basado en MLLMs:** Un componente de software que, utilizando MLLMs, procesa los datos integrados para generar al menos 100 informes de estrategia agrícola sostenible personalizados y planes de acción concretos por trimestre para comunidades y autoridades locales. (Corresponde al Objetivo Específico 2)
- **Sistema Eco-Vigilancia Austral Operativo y Validado en Campo:** La implementación funcional y probada del sistema híbrido completo (incluyendo la red logística de drones, el módulo MLLM de detección y el generador de estrategias) en al menos tres comunidades piloto en Sudamérica, demostrando su operatividad, usabilidad y eficacia real. (Corresponde al Objetivo Específico 3)
- **Informes de Validación de Campo y Análisis de Feedback de Usuarios:** Documentación exhaustiva que detalla los resultados de las pruebas en campo, incluyendo una puntuación promedio de satisfacción de los usuarios finales de 4.0/5.0 en la usabilidad y utilidad del sistema, y recomendaciones para su mejora continua. (Corresponde al Objetivo Específico 3)

- **Guías y Materiales de Capacitación para Usuarios Finales:** Conjunto de recursos didácticos y manuales de operación diseñados para empoderar a las comunidades locales, organismos gubernamentales y agrícolas en el uso y aprovechamiento efectivo del sistema Eco-Vigilancia Austral.

8.2. Impactos Esperados

- **Impacto Técnico/Científico:**

Este proyecto impulsará significativamente el estado del arte en la aplicación de Modelos de Lenguaje Grandes Multimodales (MLLMs) para la teledetección ambiental y la toma de decisiones estratégicas. Se desarrollarán nuevas metodologías para la integración de datos hiperespectrales y multiespectrales de drones con capacidades de razonamiento de MLLMs, logrando una precisión y granularidad sin precedentes en la detección de deforestación. Esto establecerá un nuevo paradigma en el monitoreo ambiental, y la capacidad de los MLLMs para generar planes de acción coherentes representa un avance crucial en la inteligencia artificial aplicada a la sostenibilidad.

- **Impacto Económico:**

La implementación de Eco-Vigilancia Austral generará impactos económicos positivos al optimizar la asignación de recursos destinados a la conservación y la gestión agrícola. La detección temprana y precisa de la deforestación reducirá las pérdidas económicas asociadas a la degradación del suelo y la pérdida de recursos naturales. Además, la generación de estrategias agrícolas sostenibles permitirá a las comunidades locales mejorar la productividad de sus tierras de manera eco-amigable, potencialmente abriendo nuevas vías de ingresos a través de prácticas sostenibles y la valorización de productos certificados, fomentando una economía regional más resiliente y verde.

- **Impacto Social y Ambiental:**

El impacto ambiental principal será la reducción significativa de la deforestación y la promoción de la conservación de ecosistemas vitales en Sudamérica, contribuyendo directamente a la mitigación del cambio climático y la protección de la biodiversidad. Socialmente, el proyecto empoderará a las comunidades locales y autoridades con herramientas de vanguardia para la toma de decisiones informadas sobre el uso de la tierra y la implementación de prácticas agrícolas sostenibles. Esto mejorará la seguridad alimentaria, fortalecerá la gobernanza territorial y fomentará la participación activa en la gestión ambiental, construyendo resiliencia social frente a los desafíos ambientales.

9. Referencias Bibliográficas

- Bie, Y., Xu, G., & Wang, Y. (2025). *Adapting Vision-Language Models for Precision Agriculture: A Study on Crop Segmentation based on UAV Remote Sensing Data*. Semantic Scholar.
- Buitrago Bolívar, E., Rico Franco, J. A., & Rojas Amador, S. (2024). Monitoreo de cultivos y suelos en agricultura de precisión con UAV e inteligencia artificial: una revisión. *Revista de la Facultad de Ciencias Agrarias*, 56*(1).
- Forbes Colombia. (2023, 6 de septiembre). *Cómo están empezando a usar IA para la conservación de la Amazonía*. Recuperado de <https://forbes.co/2023/09/06/ia/inteligencia-artificial-en-la-selva-amazonica/>
- Hernández, B., Bazán, V., Rojas, L., & García, J. (2024). *Radar, imágenes hiperespectrales y aprendizaje profundo. Herramientas de monitoreo minero para el cono sur americano: una revisión de la literatura*. Semantic Scholar.

- Koksal, A., & Alatan, A. A. (2025). *TinyRS-R1: Compact Multimodal Language Model for Remote Sensing*. ArXiv.
- Liu, C., Zhang, J., Chen, K., Wang, M., Zou, Z., & Shi, Z. (2025). *Remote Sensing SpatioTemporal Vision-Language Models: A Comprehensive Survey*. ArXiv.
- Mena Salgado, E., Galeana Brito, G., Estrada Miranda, M., Alonso Pérez, E. P., & Flores Hernández, D. A. (2025). *Tecnologías Innovadoras en la Agricultura de Precisión*. Semantic Scholar.
- Sánchez Palacios, L. E., Martínez Alcivar, F. R., Torres Sánchez, S. T., Lascano Montes, A. C., & Terán Guajala, G. N. (2024). *Agricultura de Precisión en El Ecuador*. Semantic Scholar.
- Tan, C., Cao, Q., Li, Y., Zhang, J., Yang, X., Zhao, H., Wu, Z., Liu, Z., Yang, H., Wu, N., Tang, T., Ye, X., Chai, L., Liu, N., Li, C., Mu, L., & Liu, T., Mai, G. (2023). *On the Promises and Challenges of Multimodal Foundation Models for Geographical, Environmental, Agricultural, and Urban Planning Applications*. Semantic Scholar.
- Tariq, A., & Mumtaz, F. (2023). A series of spatio-temporal analyses and predicting modeling of land use and land cover changes using an integrated Markov chain and cellular automata models. *Arabian Journal of Geosciences*, 16*(10), 874.
- TypeFly. (sin fecha). *TypeFly: Flying Drones with Large Language Model*. Recuperado de <https://typefly.github.io/>
- Uniandes. (sin fecha). *Inteligencia artificial para salvar el Amazonas*. Recuperado de <https://www.uniandes.edu.co/es/noticias/medio-ambiente/guacamaya-para-salvar-la-amazonia-con-inteligencia-artificial>
- Vera Medranda, E., & Zambrano Solórzano, T. (2025). *Impacto de drones en la agricultura: aplicaciones y beneficios en la producción de cultivos*. Semantic Scholar.
- Weng, X., Pang, C., & Xia, G. S. (2025). *Vision-Language Modeling Meets Remote Sensing: Models, Datasets and Perspectives*. ArXiv.
- WWF. (2023, 20 de septiembre). *Forest Foresight: una solución basada en inteligencia artificial para combatir la deforestación ilegal en Bolivia*. Recuperado de <https://www.wwf.org.ec/?395074/Forest-Foresight-una-solucion-basada-en-inteligencia-artificial-para-combatir-la-deforestacion-ilegal-en-Bolivia>
- Zhu, S., & Ghandeharizadeh, S. (2024). *Flight Patterns for Swarms of Drones*. ArXiv.
- Zuzuárregui, M. A., Toslak, M. M., & Carpin, S. (2025). *One For All: LLM-based Heterogeneous Mission Planning in Precision Agriculture*. ArXiv.